

WiFi 채널 상태 정보(CSI)를 활용한 사용자 상태 정보 추론



지도교수: 김태운

팀명: Wi-See

202255660 박진석

wlstjr298@pusan.ac.kr

202155527 김민준

21kimminjun@pusan.ac.kr

202055624 홍정기

bluefroq010516@pusan.ac.kr

목차

1. 서론.....	4
1.1 연구 배경	
1.2 연구 목표	
2. 시스템 설계 및 구현.....	6
2.1 전체 시스템 구조	
2.2 개발 도구 및 기술 스택	
3. 요구조건 및 제약 사항 분석에 대한 수정사항	8
3.1 신뢰성 있는 패킷 수집을 위한 환경 최적화	
3.1.1 최적 채널 탐색	
3.1.2 데이터 수집 효율 향상을 위한 통신 방식 개선	
4. 연구 내용	11
4.1 ESP32 기반 802.11n 통신 규격 및 패킷 분석	
4.1.1 프로토콜 및 패킷 구조	
4.1.2 직교 주파수 분할 다중화(OFDM) 서브캐리어 구조	
4.2 CSI 데이터 송수신 및 시각화	
4.2.1 채널 필터 설정에 따른 진폭 특성 분석	
4.2.2 전력 스펙트럼 밀도(PSD) 기반 주파수 영역 분석	
4.3 임계치 기반 재실 유무 탐지	
4.3.1 실험 환경 구성	
4.3.2 특성 추출 및 임계치 설정	

4.3.3 실험 결과	
4.4 딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지	
4.4.1 1D CNN	
4.4.2 실험 환경 구성	
4.4.3 학습 데이터셋 수집	
4.4.4 데이터 전처리 및 모델 학습	
4.4.5 실험 결과	
4.5 머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지	
4.5.1 XGBoost	
4.5.2 실험 환경 구성	
4.5.3 학습 데이터셋 수집	
4.5.4 데이터 전처리 및 모델 학습	
4.5.5 실험 결과	
4.6 RSSI	
4.7 MINIROCKET	
5. 중간 결과 및 향후 연구 방향	36
6. 구성원별 역할 및 과제 추진 계획	37
6.1 구성원별 역할	
6.2 과제 추진 계획	
7. 참고 문헌	39

1. 서론

1.1 연구 배경

최근 인구 고령화와 가구 형태의 변화로 인해 독거노인 가구 비율은 꾸준히 증가하고 있다.




그림 1. 통계청, 「2000~2024년 독거노인가구 비율 추이」, 2025.

이러한 독거 노년층에게 가장 치명적인 위협은 실내 낙상 사고이다. 질병관리청의 통계에 따르면, 70세 이상 낙상 환자 비율은 2014년 17.1%에서 2024년 35.3%로 10년 만에 2.1배 급증했다. 특히 전체 낙상 사고의 43.6%가 거실, 화장실, 침실 등 일상적인 주거 공간 내에서 발생하는 것으로 나타났다. 고령층의 낙상은 외상성 뇌손상(52.4%)이나 골절(39.4%) 등 중증 외상으로 직결된다. 따라서 홀로 거주하는 상태에서 실내 낙상이 발생할 경우, 즉각적인 구조 요청이 불가능하여 치명적인 결과로 이어질 위험이 크다.




그림 2. 질병관리청, 「낙상환자의 연령별 분포(2014년, 2024년)」, 2025.

이러한 사고를 사전에 예방하기 위해, 실내 공간의 재실 여부와 활동 패턴을 실시간으로 파악하는 기술의 중요성이 보안 및 헬스케어 분야에서 점차 커지고 있다.

1.2 연구 목표

기존의 실내 모니터링 시스템은 주로 카메라를 활용한 영상 기반 인식 방식을 채택해 왔으나, 이는 사적인 주거 공간에서 사용자의 사생활을 침해할 수 있다는 한계를 지닌다. 따라서 본 연구의 핵심 목표는 이러한 사생활 침해 문제를 배제함과 동시에, 실내 인원의 재실 여부와 활동 상태를 실시간으로 감지할 수 있는 비접촉·비시각적 공간 인지 기술을 개발하는 것이다.

결론적으로 이러한 기술로 독거노인 가구에서 발생하는 낙상 등 치명적인 응급 상황을 즉각적으로 인지하고 대처할 수 있는 차세대 스마트 홈 및 헬스케어 모니터링 시스템의 핵심 기술적 토대를 마련하는 것을 목적으로 한다.

2. 시스템 설계 및 구현

2.1 전체 시스템 구조

본 연구의 시스템 구조는 크게 데이터 수집 및 전처리, 인공지능 기반 상태 추론, 실시간 모니터링 및 시각화 파이프라인으로 구성된다.

먼저 데이터 수집 및 전처리 단계에서는 소형 하드웨어 ESP32 수신기(Rx)를 활용한다. 실내 공간에 송출된 Wi-Fi 신호는 사람의 움직임에 의해 인체 반사 및 회절을 겪으며 다중 경로 환경을 변화시킨다. 수신기는 이처럼 재실자에 의해 왜곡된 신호를 수신하여 OFDM 통신 방식의 각 서브캐리어별 채널 주파수 응답을 담고 있는 CSI(Channel State Information) 데이터를 실시간으로 추출하고 이를 메인 프로세스로 전달한다.

인공지능 기반 상태 추론 단계에서는 메인 프로세스가 수신기로부터 전달받은 CSI 시계열 데이터를 전처리한 후, 이를 머신러닝 및 딥러닝 모델에 입력하여 상태를 추론한다.

마지막으로 실시간 모니터링 및 시각화 단계에서는 서버가 메인 프로세스로부터 전달받은 추론 결과를 가공하여 웹 기반의 대시보드에 출력한다. 이를 통해 다른 공간에 있는 보호자 또한 대상자의 상태를 실시간으로 파악할 수 있다.




그림 3. 전체 시스템 구조

2.2 개발 도구 및 기술 스택

요소	내용
	ESP32-DEVKIT V4(WROOM-32E) - Wi-Fi CSI를 송신 및 수신하기 위한 HW - 송신기 1대와 수신기 2대를 사용
	PlatformIO 3.3.4 - 서버캐리어별 Raw I/Q 데이터를 실시간 수집하여 전처리 프로세스로 전달하는 ESP32 펌웨어 개발 및 업로드 환경으로 사용
데이터 수집 및 전처리	Python 3, NumPy 2.0.2, Pandas 2.2.2, SciPy 1.17.1 - 데이터 수집 및 전처리 단계에서 ESP32 를 통해 64 개 서버캐리어의 Raw I/Q 데이터를 실시간으로 수집 및 저장. - 64 개의 서버캐리어 중 55 개의 유효 서버캐리어를 추출하여 진폭을 계산하고, 윈도우 단위 분할 및 Z-score 정규화를 수행. - 정규화된 데이터에서 8 가지 통계적 특징을 추출해 벡터화한 뒤, 모델 학습을 위한 Train, Val, Test 데이터셋으로 분할.
ML/DL	Google Colab - GPU 기반 모델 학습 환경 Python 3.12.13 - Colab 내 파이썬 버전 PyTorch 2.10.0+cu128 - DL 모델 구현 및 학습 프레임워크 Numpy 2.0.2 - CSI 진폭/위상 배열 수치 연산 Pandas 2.2.2 - csv 로 저장된 시계열 데이터 로드 Scikit-learn 1.6.1 - ML 모델 학습 및 성능 평가 ML 모델: XGBoost - 특징 벡터 기반 분류, DL 모델과의 성능 비교 baseline 으로 활용. DL 모델: 1D CNN - CSI 시계열 데이터의 시공간적 패턴 학습을 통해 상태 분류 MINIROCKET - 무작위 합성곱 커널을 사용하여 111 개 채널의 다변량 시계열 데이터에서 특징을 빠르게 추출하는 분류 모델

표 1. 개발 도구 및 기술 스택


3. 요구조건 및 제약 사항 분석에 대한 수정사항

3.1 신뢰성 있는 패킷 수집을 위한 환경 최적화

3.1.1 최적 채널 탐색

동일한 통제 환경에서 패킷 데이터를 수집하더라도, 시간의 경과 및 주변 환경 요인에 따라 수신 데이터의 변동성이 크게 나타나는 문제가 발생하였다. 이러한 신호의 불안정성은 수집된 데이터의 신뢰성을 저하시키는 주요 원인이다. 따라서 외부 노이즈 및 전파 간섭을 최소화하고, 데이터 변화량이 가장 적은 안정적인 상태를 확보하기 위해 다음과 같이 수집 환경 최적화를 수행하였다. 최적화를 수행한 공간은 PBL 실 2(301-2 호)이다.

본 프로젝트에 사용되는 ESP32 모듈은 2.4GHz 대역(802.11 b/g/n)을 지원하므로, 5GHz 대역의 스캔 결과값을 배제하고 2.4GHz 대역에 한정하여 분석하였다. 아래 그림은 맥북 에어(M1)의 Wireless Diagnostics 내장 앱을 사용하여 주변 무선 네트워크 환경을 스캔한 결과이다. 해당 스캔 데이터를 분석한 결과, 주변 공유기와의 전파 중첩 및 간섭이 가장 적은 11번 채널이 데이터 수집을 위한 최적의 통신 채널로 확인되었다.



Summary		Network Name	BSSID	Security	Protocol	RSSI	Noise	Channel	Band	Width	Country
Total	22		70:bd:96:98:62:23	Open	802.11ax	-58	-91	6	2.4GHz	20MHz	KR
2.4GHz Count	6	305_2.4GHz	36:c5:99:8f:0e:d8	WPA2 Personal	802.11be	-82	-93	6	2.4GHz	20MHz	KR
5GHz Count	16	[LG_CeilingCassette A/C]23a3	16:7f:67:bc:23:a3	WPA2 Personal	802.11n	-91	-91	11	2.4GHz	20MHz	US
6GHz Count	0	DdlM	58:86:94:81:07:fc	WPA2 Personal	802.11ax	-89	-92	7	2.4GHz	40MHz	KR
Current Channel Count	2	iptime	b0:38:6c:2f:04:6c	Open	802.11ax	-81	-92	2	2.4GHz	40MHz	KR
Best 2.4GHz	11	pnuce_6202(2G)	70:5d:cc:93:2c:5c	Open	802.11n	-80	-92	5	2.4GHz	40MHz	-
Best 5GHz	161		30:c5:99:8f:0e:d9	WPA2 Personal	802.11be	-92	-89	40	5GHz	160MHz	KR
		305_5GHz	36:c5:99:8f:0e:d9	WPA2 Personal	802.11be	-93	-89	40	5GHz	160MHz	KR
		eduroam	70:bd:96:98:2b:ef	WPA/WPA2 Enterprise	802.11ax	-48	-91	44	5GHz	40MHz	KR
		eduroam	70:bd:96:98:62:2f	WPA/WPA2 Enterprise	802.11ax	-53	-91	116	5GHz	40MHz	KR
		eduroam	70:bd:96:98:63:0f	WPA/WPA2 Enterprise	802.11ax	-91	-91	48	5GHz	40MHz	KR
		eduroam	94:0d:4b:ea:65:07	WPA/WPA2 Enterprise	802.11ax	-92	-92	157	5GHz	40MHz	KR
		eduroam	94:0d:4b:ea:65:0f	WPA/WPA2 Enterprise	802.11ax	-92	-91	36	5GHz	40MHz	KR
		eduroam	94:0d:4b:ea:7a:27	WPA/WPA2 Enterprise	802.11ax	-83	-91	157	5GHz	40MHz	KR
		eduroam	94:0d:4b:ea:7a:2f	WPA/WPA2 Enterprise	802.11ax	-90	-91	48	5GHz	20MHz	KR
		PNU-WiFi	70:bd:96:98:2b:...	Open	802.11ax	-48	-91	44	5GHz	40MHz	KR
		PNU-WiFi	70:bd:96:98:62:2e	Open	802.11ax	-53	-91	116	5GHz	40MHz	KR
		PNU-WiFi	70:bd:96:98:63:0e	Open	802.11ax	-91	-91	48	5GHz	40MHz	KR
		PNU-WiFi	94:0d:4b:ea:65:06	Open	802.11ax	-93	-92	157	5GHz	40MHz	KR
		PNU-WiFi	94:0d:4b:ea:65:0e	Open	802.11ax	-91	-89	36	5GHz	40MHz	KR
		PNU-WiFi	94:0d:4b:ea:7a:26	Open	802.11ax	-83	-91	157	5GHz	40MHz	KR
		PNU-WiFi	94:0d:4b:ea:7a:2e	Open	802.11ax	-90	-91	48	5GHz	20MHz	KR

그림 4. Wireless Diagnostics 스캔 결과

3.1.2 데이터 수집 효율 향상을 위한 통신 방식 개선

초기 시스템은 10Hz의 수집 주기 환경에서 수신된 CSI 데이터를 ASCII 문자열 포맷("CSI_DATA, -13, [12, -4, ...]")으로 변환하여 시리얼 통신을 통해 전처리 프로세스로 전송하였다. 그러나 수집 주기를 40Hz로 4배 상향하고, 통신 속도를 921600 bps로 높이는 과정에서 ESP32 수신기의 오버헤드 및 시리얼 버퍼 오버플로우로 인한 패킷 유실을 발견하였다. 이는 빠른 데이터 수집 주기 대비 텍스트 변환 및 직렬화 과정이 갖는 비효율성 때문이었다.

이를 해결하고 40Hz의 고속 패킷 스트리밍을 안정적으로 지원하기 위해, 수신기의 데이터 처리 및 전송 아키텍처를 다음과 같이 최적화하였다.

- 문자열 방식에서 바이너리 페이로드 전송으로 전환

기존의 Serial.print()를 이용한 ASCII 문자열 전송 방식은 데이터 크기를 크게 늘린다. 예를 들어, 1바이트의 음수 데이터('-128')를 문자열로 전송하면 ','를 포함해 5바이트가 소모된다. 이를 해결하기 위해 수신된 원본 CSI 데이터를 문자열로 변환하지 않고, 메모리 복사(memcpy)를 통해 바이너리 형태 그대로 버퍼(uint8_t buf)에 담아 Serial.write()로 일괄 전송하도록 수정하였다. 이를 통해 송신 페이로드의 크기를 1/3 이하로 대폭 압축하였으며, ESP32의 텍스트 파싱 오버헤드를 제거하여 921600 bps 대역폭의 효율을 높일 수 있었다.

- FreeRTOS 큐를 활용한 비동기 데이터 파이프라인 구축

기존 코드에서는 Wi-Fi 수신 인터럽트 콜백 함수 내에서 직접 시리얼 출력을 수행하여, 시리얼 전송이 지연될 경우 수신 처리가 병목을 겪는 구조적 한계가 있었다. 따라서 최적화된 구조에서는 콜백 함수 내에서 시간 소모가 큰 I/O 작업을 배제하고, 수신된 데이터를 FreeRTOS의 xQueueSendFromISR을 통해 내부 큐에 즉시 적재만 하도록 분리하였다. 이후 메인 루프(loop())에서 비동기적으로 큐를 읽어 시리얼 포트에 전송함으로써, 고주파수(40Hz) 수신 환경에서도 Blocking 없이 실시간 데이터 수집이 가능하도록 시스템 안정성을 확보하였다.

- 데이터 무결성 검증 및 동기화 헤더 도입

고속의 바이너리 통신에서는 데이터 프레임의 경계를 인식하기 어려우므로 수신 측인 전처리 프로세스에서 패킷 밀림 현상이 발생할 수 있다. 이를 방지하기 위해 전송 버퍼의 선두에 고정된 동기화 바이트(SYNC0: 0xAA, SYNC1: 0xBB)와 데이터 길이를

배치하였다. 또한, 타임스탬프, 시퀀스 번호, 그리고 페이로드 전체에 대한 XOR 체크섬 필드를 추가하여, 고속 통신 환경에서도 오차나 유실 위치를 정확히 감지하고 필터링할 수 있는 프로토콜을 완성하였고 이는 전처리 프로세스에서 모듈로 사용한다.

```
memcpy(&buf[idx], &seq_num, 2); idx += 2;
memcpy(&buf[idx], &ts_us, 4); idx += 4;
buf[idx++] = (uint8_t)rss;
memcpy(&buf[idx], &length, 2); idx += 2;
memcpy(&buf[idx], item.csi_data, length);
idx += length;

// 체크섬 계산 (파이썬 코드: offset 2 부터 HEADER_LEN+length-1 까지 XOR)
uint8_t cs = 0;
for (int i = 2; i < idx; i++) {
    cs ^= buf[i];
}
buf[idx++] = cs;

// 완성된 이진 프레임 전송
Serial.write(buf, idx);
```

그림 5. ESP32 수신기 펌웨어 1바이트 XOR 체크섬 코드

921600bps의 고속 시리얼 통신에서 대량의 CSI 데이터를 실시간으로 전송하기 위해 1바이트 XOR 누적 체크섬을 사용한다. 연산 부하 감소와 전송 지연 최소화를 우선시하여 실시간 데이터 처리량을 확보한 대안이다.

4. 연구 내용

4.1 ESP32 기반 802.11n 통신 규격 및 패킷 분석

4.1.1 프로토콜 및 패킷 구조

ESP32 환경에서 CSI를 추출하기 위해 적용된 ESP-NOW 프로토콜의 아키텍처와 802.11n 통신 규격 기반의 프레임 구조를 물리 계층 및 데이터 링크 계층 관점에서 분석하였다.

일반적인 Wi-Fi 통신은 응용 계층의 데이터가 전송 계층(TCP/UDP)과 네트워크 계층(IP)을 거치며 다수의 헤더가 추가되어 통신 오버헤드 및 처리 시간 지연이 발생한다. 반면, 본 시스템에 적용된 ESP-NOW 프로토콜은 이러한 상위 계층을 생략하고 응용 계층의 데이터를 데이터 링크 계층(MAC)의 전용 프레임으로 직접 매핑하는 방식을 사용한다. 이를 통해 불필요한 패킷 캡슐화 과정을 제거함으로써 통신 지연 시간을 단축시키고 CSI 데이터 수집을 위한 고속 패킷 송수신 환경을 보장한다.

이러한 고속 전송 환경에서 유의미한 CSI를 획득하기 위해서는 송신기의 통신 프로토콜을 802.11n으로 강제해야 한다. 802.11n 규격은 20MHz 대역폭에서 직교 주파수 분할 다중 접속(OFDM) 방식을 통해 64개의 서브캐리어를 사용한다. 특히 물리 계층 프레임 내에 다중 안테나(MIMO) 환경의 채널 추정을 위해 고안된 HT-LTF 구간을 포함하므로, 정밀한 공간 자원 분석이 가능하다.




그림 6. 802.11n PPDU(Physical layer Protocol Data Unit)

송신기에서 전송된 802.11n 전파는 시간에 따라 위 그림과 같이 여러 필드로 전송되며 수신기는 각 필드를 다음과 같은 단계로 처리하여 CSI를 도출한다.

- L-STF, L-LTF, L-SIG (Legacy Field)

802.11a/g 등 구형 규격 장비와의 호환성 유지 및 패킷 충돌 방지를 위해 송출되는 프리앰블이다. 본 시스템은 802.11n 기반 채널 상태 추정이 목적이므로 수신기 측 펌웨어에서 (l1tf_en = false)을 통해 해당 구간의 채널 정보는 물리 계층에서 명시적으로 폐기한다.

- HT-SIG (High Throughput Signal Field)

해당 패킷의 변조 방식과 물리적 제원이 명시된 구간이다. 송신기 측 펌웨어에서 설정한 20MHz의 대역폭과 제어 전송 속도인 MCS0 정보가 포함되어 있다. CSI 데이터 수집 시 패킷 손실을 최소화하고 신호의 안정성을 확보하기 위해 BPSK 기반의 가장 보수적인 변조 방식인 MCS0을 적용하였으며 수신기는 이를 디코딩하여 후속 필드 해석의 기준으로 삼는다.

- HT-STF (High Throughput Short Training Field)

후속되는 HT-LTF 신호를 정확하게 획득하기 위한 타이밍 동기화를 수행하는 구간이다.

- HT-LTF (High Throughput Long Training Field)

공간상의 전파 왜곡을 측정하기 위해 사전에 약속된 기준 신호 구간이다. 송신기가 발사한 원본 파형은 공간을 이동하며 다중 경로 페이딩, 잡음 등에 의해 진폭과 위상 변화를 겪는다. 수신기의 물리 계층 하드웨어는 수신된 왜곡 신호와 원본 신호를 비교 연산하여, 20MHz 대역 내 64개 서브캐리어 각각에 대한 복소수 형태의 채널 상태 정보 행렬을 역산해낸다.

- Data Field

MAC 헤더 및 응용 계층의 페이로드가 위치하는 구간이다. 송신부가 전파 방사를 유도하기 위해 발생시킨 더미 데이터가 여기에 포함되며, 수신기는 페이로드 앞단의 MAC 주소를 필터링하여 대상 패킷 여부를 최종 판별한다.

4.1.2 직교 주파수 분할 다중화(OFDM) 서브캐리어 구조

수신 안테나를 통해 들어오는 HT-LTF 신호는 시간에 따라 진동하는 연속적인 아날로그 파형이다. ESP32는 이 시간 축의 파형을 수신 후 고속 푸리에 변환을 수행한다. 이를 통해 시간 파형은 64개의 개별적인 주파수 성분으로 분해된다.

수신기 측 펌웨어의 콜백 함수(void csi_callback(void *ctx, wifi_csi_info_t *info))를 통해 획득하는 128바이트의 CSI 데이터(info->buf)는 주파수 변환이 완료된 직후의 결과물이다.

802.11n 규격은 20MHz의 대역폭을 64개의 하위 부반송파인 서브캐리어로 쪼개어 데이터를 병렬 처리한다. 아래 그림은 이 서브캐리어들의 물리적 스펙트럼 배치 구조이다.




그림 7. 20MHz 802.11n OFDM 서브캐리어 구조

이 64개 서브캐리어의 각 채널 주파수 응답은 부호가 있는 8비트 정수 2개로 총 2바이트로 구성되어 있다. 첫 번째는 허수부, 두 번째는 실수부이다. 이러한 복소수 형태로 짝을 이루어 128바이트 버퍼 안에 담기게 된다. 64개의 서브캐리어는 스펙트럼 상의 위치에 따라 다음과 같이 세 가지 역할로 분류된다.

- 데이터 서브캐리어 (52개): 실제 데이터가 실리는 구간으로, 전파가 공간을 통과하며 겪는 사람의 이동 등과 같은 물리적 환경 변화에 따른 왜곡이 가장 뚜렷하게 반영된다. 향후 머신러닝 모델의 주력 특성 데이터로 활용된다. 본 시스템에 적용된 802.11n(HT20) 규격은 가드 밴드를 축소하여 4개의 데이터 서브캐리어를 추가 확보하였다. 따라서 실제

운용되는 데이터 서브캐리어는 총 52개이다.

- 파일럿 서브캐리어 (4개): 송수신기 간의 동기화를 위해 사전에 약속된 기준 신호 구간이다.
- Null 서브캐리어 (8개): 신호 간섭 방지를 위해 전력을 할당하지 않는 빈 대역이다. 중심 주파수(DC) 1개와 대역 양끝의 가드 밴드 7개로 구성되며, 전파 왜곡이 아닌 하드웨어 노이즈만 수집되므로 전처리 과정에서 제거 대상이 된다.

PHY standard	Total Subcarriers	Pilot Subcarriers	Null Subcarriers
802.11n, 20 MHz	[-32, 31]	-21, -7, 7, 21	[-32, -29], [0], [29, 31]

표 2. 802.11n 20MHz 서브캐리어 인덱스

ESP32 물리 계층에서 고속 푸리에 변환 직후 출력되는 원시 데이터 버퍼의 배열 순서는 위 표에 명시된 인덱스 순서와 일치하지 않는다.

하드웨어의 출력 특성상 중심 주파수와 양의 주파수 대역이 배열 앞단에 배치되고 음의 주파수 대역이 뒷단으로 밀려나 순서가 뒤섞여 있기 때문이다. 또한 DC 인접 서브캐리어도 신호가 훼손됨을 확인하여 임계치 기반 모델 이후로는 DC 인접 서브캐리어 하나를 추가로 제외하였다.

따라서 수집된 CSI 데이터를 시각화하거나 머신러닝 모델의 특성 데이터로 온전히 활용하기 위해서 이후 데이터 전처리 과정에서 fftshift 연산을 수행하여 배열의 순서를 연속적인 물리적 스펙트럼 오름차순으로 재정렬하는 과정을 추가하였다.

4.2 CSI 데이터 송수신 및 시각화

4.2.1 채널 필터 설정에 따른 진폭 특성 분석

이전에 설계한 ESP-NOW 기반의 통신 환경을 통해 패킷의 CSI 데이터를 수집하고 서브캐리어에 대한 주파수 영역의 진폭을 ESP32 펌웨어의 CSI 설정 구조체(wifi_csi_config_t)에 포함된 내부 대역 필터링 옵션인 channel_filter_en의 활성화 여부에 따라 시각화한 결과를 분석하였다. 채널 필터는 인접 채널 간섭 및 대역 외 잡음을 억제하기 위한 ESP32 하드웨어 내부의 디지털 필터이다.

서브캐리어의 진폭은 수신된 버퍼의 허수부(Q, Quadrature)와 실수부(I, In-phase) 값을 바탕으로 다음 식과 같이 계산된다.

$$Amplitude = \sqrt{Q^2 + I^2}$$




그림 8. 채널 필터 활성화 시 서브캐리어들의 원시 진폭 그래프

채널 필터를 활성화한 상태에서 추출된 진폭 그래프는 필터가 서브캐리어 간의 급격한 변화율을 억제하여, 진폭 그래프가 전체적으로 평탄화되거나 부드러운 곡선 형태로 나타났다. 이 설정은 통신 모뎀 입장에서 신호의 신뢰성을 높이고 잡음을 제거하는 데는 유리하지만, CSI 센싱 관점에서는 단점으로 작용한다. 공간 변화에 의해 발생한 유의미한 전파 왜곡을 하드웨어가 통신 노이즈로 간주하여 깎아내리기 때문이다.

다음으로, 채널 필터를 비활성화 하였을 때의 그래프이다.




그림 9. 채널 필터 비활성화 시 서브캐리어들의 원시 진폭 그래프

위 그래프는 주파수 대역별 진폭의 변동성이 크고, 서브캐리어 간의 미세한 굴곡이 선명하게 나타난다. 하드웨어가 평탄화를 위해 개입하지 않았기 때문에, 사람의 미세한 움직임이나 위치 변화 등 공간의 물리적 변화가 진폭 파형에 즉각적이고 예민하게 반영된다. 따라서 환경 감지나 행동 인식 머신러닝 모델을 학습시키기 위한 특성 데이터 수집에 적합한 상태로 판단하였다.

따라서 본 프로젝트의 목적에 부합하는 데이터를 수집하기 위해서는, 수신기 측 펌웨어에서 명시적으로 `channel_filter_en = false`로 설정하여 하드웨어의 신호 왜곡 개입을 차단하였다.

4.2.2 전력 스펙트럼 밀도(PSD) 기반 주파수 영역 분석

앞서 시간 축에서 확인한 CSI 진폭의 변화량은 직관적이지만 특정 움직임의 패턴이나 주기를 정량화하기에는 한계가 있다. 따라서 특정 움직임의 패턴을 확인하기 위해 수집된 시간 데이터에 스펙트럼 분석을 적용하여 주파수 영역에서의 에너지 분포를 시각화하고 분석하였다.

본 시스템의 표본화 주파수인 패킷 송수신 속도는 10 Hz로 설정되어 있다. 나이퀴스트 이론에 따르면, 시스템이 왜곡 현상 없이 온전히 복원할 수 있는 최대 유효 주파수는 다음 식과 같이 표본화 주파수의 절반이다. 따라서 주파수 분석 대역을 0~5 Hz 구간으로 설정 후 전력 스펙트럼 밀도를 시각화하였다.




그림 10. 5.0초 윈도우 기반 서브캐리어의 Periodogram

회색 선은 서브캐리어 각각이 가지는 주파수별 에너지 분포를 나타낸다. 서브캐리어마다 중심 주파수 파장이 다르므로, 동일한 공간적 변화에 대해서도 각기 다른 다중 경로 페이딩 응답을 보여 다양한 형태의 스펙트럼이 겹쳐서 나타난다. 붉은 색 선은 52개 서브캐리어의 주파수별 에너지 평균 값이다.

실시간 시각화 분석 결과, 통신 공간 내 사람의 움직임 여부에 따라 주파수 대역별 에너지 분포가 움직임 발생 시 0 Hz보다 큰 유효 주파수 대역 전반에서 신호 에너지가 확연히 상승하였고, 정지 시 변화 폭이 크게 줄어들며 주파수가 0 Hz에 가까운 저주파 대역에 에너지가 집중되는 것을 확인하였다.

이처럼 대상의 동적, 정적 상태에 따라 CSI 진폭 및 특정 주파수의 에너지가 뚜렷한 차이를 보인다는 점을 확인하였다. 따라서 진폭과 주파수 에너지는 임계치 기반 재실 유무 탐지를 설계하기 위한 판별 지표로 활용되었다.

4.3 임계치 기반 재실 유무 탐지

4.3.1 실험 환경 구성

데이터 수집 및 실시간 분석 알고리즘은 Python 환경(pyserial, scipy, numpy)을 기반으로 구축되었다. ESP32 수신기, 수신기와 연결된 노트북간의 시리얼 통신을 통해 초당 약 10회의 샘플링 속도로 물리 계층의 CSI 패킷을 수집하도록 환경을 구성하였다.

아래 사진은 ESP32 송수신기가 1:1로 설치된 실제 환경이다.



그림 11. 실제 환경 구성. PBL실2(301-2호)

ESP32가 반환하는 64개의 서브캐리어 원시 배열 중 802.11n(HT20) 규격에 맞추어 상/하위 가드 밴드, DC 성분의 중심 주파수, 파일럿 서브캐리어를 인덱스 기반으로 제거하는 데이터 전처리를 수행하였다. 그 결과, 공간의 물리적 변화를 가장 민감하게 반영하는 52개의 유효 데이터 서브캐리어 정보만을 추출하여 분석에 활용하였다.

4.3.2 특성 추출 및 임계치 설정

사람의 움직임이나 위치 변화는 다중 경로 파편화를 유발하며, 이는 수신된 CSI의 진폭 변화로 나타난다. 해당 알고리즘은 5초 분량인 50개의 패킷을 하나의 슬라이딩 윈도우로 묶어 다음 두 가지 지표를 추출하였다.

- 진폭의 분산: 수신기와 송신기 간의 거리나 장애물의 배치 등 측정 환경이 달라지면 수신되는 CSI의 절대적인 기저 진폭 수준이 크게 변하게 된다. 이러한 DC Offset 차이를 배제하고, 오직 사람의 움직임으로 인해 발생하는 진폭의 순수한 변화량에만 집중하기 위해 윈도우 내 데이터의 분산을 계산하였다.

분산의 연산 과정에는 평균 중심화가 포함되므로 절대적인 진폭의 높낮이는 무시되며, 정적 상태일 때보다 움직임이 발생할 때 파형의 요동이 커지면서 분산 값이 급격히 상승한다.

- 1~4 Hz 대역의 주파수 에너지: 사람이 걷거나 팔을 흔드는 등의 일반적인 움직임은 주파수 영역에서 주로 1~4 Hz 대역에 집중된다. 이를 수치화하기 위해 시간 축의 진폭 윈도우를 Periodogram 함수를 통해 주파수 영역으로 변환하고, 1~4 Hz 대역에 분포하는 전력 스펙트럼 밀도의 총합을 구하였다. 이 대역을 벗어나는 고주파 신호는 하드웨어 노이즈로 간주하여 필터링하였다.

추출된 두 가지 지표를 바탕으로, 실시간 재실 유무를 판별하기 위한 임계치는 진폭 분산은 26.0, 1~4 Hz 에너지는 350.0 으로 설정하였다.

슬라이딩 윈도우 연산 시마다 위 두 가지 조건 중 하나라도 임계치를 초과할 경우 해당 시점의 상태를 재실(Presence = 1)로 판별하며, 두 지표 모두 임계치 미만일 경우 빈 방(Empty = 0)으로 판별한다. 이 결과는 추출된 특성 값들과 함께 타임스탬프 기준으로 CSV 파일에 실시간 누적 기록된다.

4.3.3 실험 결과




그림 12. 시간에 따른 진폭 분산 및 1~4Hz 주파수 에너지 변화 추이

측정 결과를 살펴보면 두 지표가 유사한 추세를 보이는 것을 알 수 있다. 공간 내에 사람의 움직임이 존재하는 구간(10~15초, 20~30초)에서는 두 수치가 높게 유지되지만, 사람이 퇴실하거나 완전한 정지 상태를 유지하는 구간(5~10초, 15~20초)에서는 수치가 급격히 하락함이 관측되었다.

442	49.1	31.18797874	378.1084595	1
443	49.2	30.60311508	356.7941895	1
444	49.3	30.15510178	350.2645569	1
445	49.4	29.48429108	355.8590088	0
446	49.5	29.60929298	369.0174255	0
447	49.6	27.54317474	324.2199097	0
448	49.7	26.04083443	300.9173279	0

그림 13. CSV 파일 일부 (실행 시간 | 진폭 분산 | 주파수 에너지 | 재실 유무 판별 결과)

위 그림의 CSV 데이터 로그는 추출된 두 가지 특성 값과 판별 결과가 타임스탬프에 맞춰 실시간으로 기록되었음을 보여준다. 또한 방을 나간 후 진폭 분산과 주파수 에너지가 떨어지는 것을 확인할 수 있다.

측정 시작후 방으로부터 나가기까지 결과는 무시하기 위해 측정 시작 5초 후부터 수집된 데이터를 CSV 파일로 저장했다. 5~10초 및 15~20초 구간은 방에 사람이 없는 상태로, 10~15초 및 20~30초 구간은 방에서 사람이 움직이는 상태로 설정해 측정하였다. 이 실제 상황과 임계치 기반 모델의 예측값을 csv파일에 저장된 값과 비교 분석한 결과 약 45.4%의 정확도를 확인했다.

실험 결과 실시간 재실 탐지가 가능함을 확인하였으나, 현재 적용된 고정 임계치 방식은 환경이 변할 때마다 수동으로 임계치를 재설정해야하고, 설정한 임계치에 따라 정확도에 크게 달라지는 한계가 있다. 따라서 임계치 기반 탐지 로직은 향후 도입될 ML/DL 모델의 정상 동작 여부 및 성능 향상 폭을 객관적으로 비교 평가하기 위한 기초 기준으로 활용된다.

4.4 딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지

4.4.1 1D CNN

1D CNN에서 CNN은 Convolutional Neural Network(합성곱 신경망)의 약자로, 이미지 처리와 패턴 인식에 사용되는 인공지능망의 한 종류이다.

1D CNN은 시계열 데이터와 같은 1차원 축을 따라 배열된 순차적 데이터로부터 시간적 흐름에서의 패턴 특징을 추출하여 학습하고, 2차원 이미지를 학습할 수 있는 2D CNN은 픽셀들로 이루어진 이미지 데이터의 공간적 특징인 (R, G, B)의 정보를 격자 상에서 추출하여 학습한다.

학습을 위해 CNN은 크게 합성곱층(Convolutional Layer), 풀링층(Pooling Layer), 밀집층(Fully Connected Layer)으로 구성되어 있다.




그림 14. 합성곱 신경망(CNN)의 기본 구조

본 실험에서 사용될 1D CNN의 합성곱 층(Convolutional Layer)에서는 1차원 배열 형태의 입력 데이터 위를 커널(Kernel)이라 불리는 필터가 순차적으로 슬라이딩하며 합성곱 연산을 수행하여 새로운 특성 맵(Feature Map)을 생성한다. 이러한 특성 맵은 입력 데이터에 내재된 시간적 패턴이 추출 및 요약된 특징을 가지며, 이후 풀링층과 밀집층을 거쳐 최종적인 데이터 분류에 이용된다. 아래 그림은 이 과정을 시각적으로 나타낸 것이다.




그림 15. 1D CNN의 1차원 슬라이딩 연산 및 특성 맵(Feature Map) 추출 과정

다음으로, 풀링 층(Pooling Layer)은 합성곱 층에서 추출된 특성 맵의 크기를 줄이는 역할을 한다. 크기를 줄이는 방법으로는 지정된 구간 내에서 최댓값을 추출하는 최대 풀링(Max Pooling)이나 평균값을 계산하는 평균 풀링(Average Pooling) 방식이 사용된다. 이를 통해 모델의 연산 비용을 줄이면서도 데이터의 중요한 특징은 보존할 수 있다.

마지막으로, 밀집층(Fully Connected Layer)은 추출된 특성 맵을 바탕으로 최종 출력 결과를 생성하는 역할을 한다. 이를 위해 먼저 평탄화 층(Flatten Layer)을 거쳐 특성 맵들을 하나의 긴 1 차원 배열로 평탄화한다. 밀집층은 이렇게 펼쳐진 지역적 특징들을 한 번에 입력으로 받아 데이터의 전체적인 패턴을 종합하고, 출력층을 통해 최종 예측값을 산출한다. 모델의 학습 과정에서는 이 최종 예측값과 실제 정답 간의 오차를 계산하며, 이를 최소화하는 방향으로 밀집층의 노드와 합성곱 층의 커널을 포함한 모델 내부의 가중치를 점진적으로 최적화해 나간다.

4.4.2 실험 환경 구성

환경 변화에 따른 변수를 배제하기 위해 송수신기 배치 및 통신 공간 환경(PBL실2)은 앞 4.3절의 임계치 기반 탐지 실험과 동일하게 유지하였으나, 샘플링 주파수와 baud rate는 각각 40 Hz와 921600으로 변경하여 구성하였다.

4.4.3 학습 데이터셋 수집

본 실험에서는 모델 학습에 필요한 고밀도 데이터를 확보하기 위해 패킷 전송률을 40Hz, Baud Rate를 921600으로 설정하였으며, 회당 측정 시간을 1분으로 통제하여 세션당 2,400개의 패킷을 수집하였다.

데이터는 피실험자 3명(A, B, C)을 대상으로, 서로 다른 3일에, 3가지 레이블에 대해 각각 5회씩 반복 측정하여 총 135개의 세션을 수집하였다. 이는 데이터 수집 과정에서 발생할 수 있는 시간적 환경 변화(온도, 외부 간섭 등)가 특정 피실험자나 레이블에 과적합되는 것을 방지하기 위함이며, 이를 위해 측정 순서 또한 무작위로 교차 배치하였다. 수집이 완료된 원시 데이터는 모델의 객관적인 성능을 평가하기 위해 학습(Train), 검증(Validation), 테스트(Test) 세트로 분할하였으며, 전체 세션의 구성은 아래 표와 같다.

데이터 분할	대상 피험자	분할별 총 세션 수	비율
Train	A, B (day1~3) + C (day1, day2)	96	약 71.1%
Validation	A, B (day1~3) + C (day1, day2)	24	약 17.8%
Test	C (day3)	15	약 11.1%

표 3. 데이터셋 수집 시나리오

또한 머신러닝 모델의 범용성과 강건성을 확보하기 위해 단일 행동의 반복 측정을 지양하고 레이블 내 세부 시나리오를 다양화했다. 데이터 수집 환경 변화와 관계없이 모델 학습을 위한 데이터 전처리 방식은 동일하게 적용된다. Standing 레이블은 단순히 가만히 서 있는 동작을 넘어 측정 시마다 피실험자가 바라보는 방향을 반대로 전환하고 서 있는 위치를 변경함으로써 인체의 방향성과 위치 변화에 따른 전파 단면적 변화를 학습에 반영했다. Moving 레이블 또한 단순 보행에 국한하지 않고 방 내부를 U자 형태로 도는 동선, 직선으로 왕복하는 동선, 불규칙하게 걷는 동선의 세 가지 서로 다른 패턴을 구성하였다.

4.4.4 데이터 전처리 및 모델 학습

전처리 이전에 원본 세션 파일 단위로 학습, 검증, 테스트 세트를 약 8:1:1 비율로 분리하였다. 이후 각 파일의 원시 CSI 데이터(64개 서브캐리어)에 fftshift를 적용하고 노이즈 대역을 제거하고, 파일럿 서브캐리어는 포함하여 55개의 유효 서브캐리어를 추출한 뒤 진폭 데이터로 변환하였다.

연속적인 행동 패턴을 반영하기 위해 변환된 진폭 데이터에 슬라이딩 윈도우(크기 200, 슬라이드 40)를 적용하여 분할하였으며, 환경적 신호 편향을 제거하고자 각 윈도우 내부에서 서브캐리어별 Z-score 정규화를 독립적으로 수행하였다.

별도의 통계적 특징 추출 없이 시간의 흐름을 보존한 이 데이터는, 1D CNN 모델의 입력 규격에 맞추어 서브캐리어를 채널로 취급하는 (55, 200) 차원의 텐서로 최종 변환된다. 모델은 3단계의 깊이별 분리 합성곱을 통해 움직임 특징을 스스로 추출하며, 조기 종료 기법을 병행하여 과적합 없이 재실 상태(Empty, Standing, Moving)를 판별할 수 있게 학습시켰다. 아래 그림은 데이터 전처리 과정에서의 텐서 차원 변화를 요약한 것이다.




그림 16. 데이터 전처리 과정의 텐서 차원 변화

4.4.5 실험 결과

아래 두 그림은 1D CNN 모델의 테스트 결과이다.

★ Final Test Results (Robust Normalization)

	precision	recall	f1-score	support
empty	0.57	0.55	0.56	270
standing	0.62	0.58	0.60	270
moving	0.87	0.95	0.91	270
accuracy			0.70	810
macro avg	0.69	0.70	0.69	810
weighted avg	0.69	0.70	0.69	810

그림 17. 1D CNN 테스트 결과




그림 18. 1D CNN 테스트 결과 혼동 행렬

moving 레이블은 F1-score 0.91, 재현율(Recall) 0.95라는 높은 성능을 기록하였다. 혼동 행렬을 보면 실제 걷고 있는 상태를 빈 방(Empty)으로 완전히 잘못 인식한 경우는 0건이다. 이는 움직임이 만들어내는 CSI 신호의 큰 변동성은 1D CNN이 시간적 특징을 잡아내기에 매우 이상적이었음을 의미한다. 하지만 시간적 변동성이 작은 empty, standing의 경우에는 이를 구분할만한 패턴을 감지하지 못하는 모델의 한계를 보여준다.

4.5 머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지

4.5.1 XGBoost

XGBoost는 eXtreme Gradient Boosting의 약자로, 결정 트리(Decision Tree)를 기반으로 하는 머신러닝 알고리즘이다.

XGBoost는 여러 개의 약한 예측 모델인 결정 트리를 순차적으로 생성하여 학습한다. 이때 이전 트리가 잘못 예측한 오차에 가중치를 부여하고, 다음 트리가 이 오차를 보완하는 방향으로 학습을 진행하는 Gradient Boosting 방식을 사용한다.

이 모델은 데이터를 분할하며 정답을 찾아가는 여러 개의 결정 트리를 생성하고, 각 트리의 예측 결과를 결합하여 최종 분류값을 산출한다. 학습 과정에서는 손실 함수(Loss Function)를 최소화하는 방향으로 트리의 구조와 가중치를 점진적으로 최적화하며, 모델의 과적합을 방지하기 위한 정규화 기법을 내장하고 있어 뛰어난 예측 성능과 일반화 능력을 제공한다.




그림 19. XGBoost 간략한 구조

4.5.2 실험 환경 구성

이번 실험의 데이터 수집 환경 및 조건은 이전 1D CNN 방식과 동일하게 설정하였다. 수집 대상 레이블의 종류와 수는 Empty, Standing, Moving의 세 가지로 기존과 같으며, 송수신기의 배치 구조 또한 동일하게 유지하였다.

4.5.3 학습 데이터셋 수집

40 Hz의 샘플링 주파수와 921600 baud rate 환경에서 수집되었고, 1D CNN 모델 학습에 활용한 총 135개의 세션 파일(.npz)을 별도의 변형 없이 XGBoost 모델 학습에도 그대로 사용하였다.

4.5.4 데이터 전처리 및 모델 학습

데이터 누수 방지를 위한 세션 파일 단위의 데이터 세트 분리부터 유효 서브캐리어(55 개) 추출, 진폭 변환, 슬라이딩 윈도우(크기 200, 슬라이드 40) 분할 및 Z-score 정규화까지의 기본 전처리 과정은 앞선 1D CNN 모델(4.4.4 절)과 동일하게 수행되었다.

2 차원 시계열 배열을 그대로 학습하는 1D CNN 과 달리 머신러닝 기반의 XGBoost 모델을 위해 추가적인 통계적 특징 추출을 진행하였다. 정규화가 완료된 각 윈도우(200, 55) 데이터에 대하여, 55 개의 유효 서브캐리어 각각에 8 가지 통계 지표(평균, 표준편차, 최댓값, 최솟값, 에너지, RMS, 왜도, 첨도)를 계산하였다. 결과적으로 단일 윈도우는 440 차원(55, 8)의 1 차원 특징 벡터로 압축된다.

이렇게 개별적으로 생성된 440 차원의 특징 벡터 데이터셋은 다중 클래스 분류를 수행하는 XGBoost 모델의 입력으로 제공된다. 알고리즘은 입력된 440 개의 특징을 기반으로 다수의 Decision Tree 를 순차적으로 생성하며 재실 상태(Empty, Standing, Moving)를 판별하도록 학습되었다. 학습 과정에서는 검증 세트의 다중 로그 손실 지표를 지속적으로 모니터링하고 조기 종료를 적용하여 모델의 과적합을 방지하였다.

아래 그림은 데이터 전처리 과정에서의 텐서 차원 변화를 요약한 것이다.




그림 20. 데이터 전처리 과정의 텐서 차원 변화

4.5.5 실험 결과

— Test 최종 성능 —				
	precision	recall	f1-score	support
empty	0.50	0.19	0.27	280
standing	0.51	0.74	0.60	277
moving	0.78	0.94	0.85	278
accuracy			0.62	835
macro avg	0.60	0.62	0.58	835
weighted avg	0.60	0.62	0.58	835

그림 21. XGBoost 테스트 결과




그림 22. 테스트 데이터셋에 대한 혼동 행렬

도출된 혼동 행렬을 분석한 결과, Moving 레이블은 총 278개의 샘플 중 261개를 정확히 분류하여 93.9%의 높은 정확도를 기록하였다. 반면, Empty 상태의 테스트 데이터 280개 중 181개를 Standing으로 오분류하는 편향이 발생하였다.

이는 측정 시간대가 완전히 다른 테스트 세션의 기저 스케일 변화를 모델이 극복하지 못했음으로 예상된다.




그림 23. 중요도 합산 결과

특징 중요도 분석 결과, 평균(Mean)이나 표준편차(Std)보다 왜도(Skewness), 첨도(Kurtosis), 최댓값과 같은 분포 기반 통계량의 기여도가 높게 나타났으며, 52개 서버캐리어 중에서도 특정 서버캐리어(sc20, sc60, sc44)에 중요도가 집중되는 경향을 보였다.



그림 24. 실시간 추론 모니터링 터미널

실제 구현된 터미널 환경에서 실시간 스트림 추론 로그를 분석한 결과, 앞선 혼동 행렬에서 확인된 모델의 한계가 동일하게 관측되었다.

Moving 의 경우 높은 신뢰도로 정확하게 탐지해 내는 우수한 성능을 보인 반면, Empty 와 Standing 구간에서는 두 상태를 빈번하게 오분류하는 한계점이 실시간 추론 환경에서도 확인되었다.

4.6 RSSI

RSSI는 수신된 무선 신호의 전체적인 절대 강도를 나타내는 지표이다. 재실 상태 중 사람이 정지해 있는 Standing의 경우, 사람이 송신기와 수신기 사이의 가시선(Line-of-Sight, LoS) 상에 위치하거나 그 주변에 서있는 경우가 존재한다. 이때 사람에 의해 신호가 감쇠되는 현상이 발생하며, 이는 전체 수신 신호 강도에 변화를 일으킨다.

앞선 실험 결과, CSI 진폭의 미세한 시간적 변동성만으로는 Empty와 Standing 상태를 완벽히 구별하는 데 한계가 존재했다. 따라서 두 상태의 분류를 명확히 하고자 RSSI 값을 추가적인 특성으로 도입하였다.

	precision	recall	f1-score	support
empty	0.68	0.39	0.49	280
standing	0.56	0.78	0.65	280
moving	0.93	0.97	0.95	280
accuracy			0.71	840
macro avg	0.72	0.71	0.70	840
weighted avg	0.72	0.71	0.70	840

그림 25. RSSI 추가 후 테스트 결과




그림 26. RSSI 추가 후 테스트 데이터셋에 대한 혼동 행렬

위 두 그림에서 확인할 수 있듯, RSSI 특성을 추가한 결과 정적 상태(Empty, Standing) 간의 분류 성능이 개선되었다. 특히 Empty를 Standing으로 잘못 예측하던 오분류 건수가 기존 181건에서 165건으로 감소하였으며 정확도는 18.6%에서 38.6%로 증가하였다. 이는 CSI의 시간적 특징에 물리적 신호 감쇠(RSSI) 정보를 결합하는 접근이 유효했음을 입증한다.

4.7 MINIROCKET

해당 절에서는 시계열 데이터 분류에 최적화된 MINIROCKET 알고리즘을 사용하였다. 1D CNN 과 같은 역전파 기반의 딥러닝 모델과 달리, MINIROCKET 은 사전에 정의된 소수의 고정된 합성곱 커널을 활용하여 복잡한 다변량 시계열 데이터에서 특징을 빠르고 효과적으로 추출하는 알고리즘이다.

이 MINIROCKET 모델의 데이터 수집 방식은 먼저 원시 데이터에서 55 개의 유효 서브캐리어를 추출한 뒤, Empty 의 정적 기준점을 계산한다. 이후 순수 진폭(55 개), 기준점 대비 진폭의 변화량(55 개), RSSI 변화량(1 개)을 결합하여 총 111 개 채널로 구성된 다변량 윈도우 텐서를 생성한다. MINIROCKET 은 이 텐서를 1 차원 특징 벡터로 변환하며, 추출된 특징은 분류기를 통해 최종적으로 Empty, Standing, Moving 을 판별하도록 학습된다.

실시간 추론 환경에서는 스크립트 실행 직후 빈 방의 기준점을 실시간으로 새롭게 보정하여 환경 변화에 따른 노이즈를 상쇄한다. 이후 수신되는 CSI 패킷을 지정된 시간(버퍼 크기)만큼 큐에 쌓아 윈도우를 구성하고, 학습된 모델을 통해 즉각적으로 특징을 변환 및 예측한다. 최종적으로 최근 N 회의 예측 결과 중 가장 빈도가 높은 클래스를 선택하는 다수결 알고리즘을 적용하여 노이즈 현상으로 인한 오작동을 방지하였다.

버퍼 크기에 따른 분류 성능을 평가하기 위해 윈도우 크기를 늘려 윈도우 크기만큼 차는 시간을 각각 20 초, 10 초, 4 초로 설정하여 모델을 학습하고 테스트를 진행하였다. 실험 결과, 버퍼 크기에 따른 분류 정확도는 20 초 모델이 89.51%, 10 초 모델이 74.59%, 4 초 모델이 84.47%로 각각 도출되었다.

수치상으로는 20 초 버퍼를 적용한 모델이 89.51%로 가장 높은 분류 정확도를 기록하였다. 그러나 모델이 상태를 판별하기 위해 20 초 분량의 패킷이 쌓이기를 기다려야 하므로 정확도와 실시간 처리 속도 간의 최적의 균형을 보여준 4 초 버퍼 모델을 최종 실시간 추론 시스템의 기준으로 선택하였다.

```

=====
MiniROCKET Single 3-class Test Report
=====

Accuracy: 84.47%

Confusion Matrix [rows=true, cols=pred]
labels: 0=empty, 1=standing, 2=moving
[[440 111  14]
 [102 454   3]
 [   6  26 531]]

```

그림 27. 4초일때의 결과 및 혼동행렬

4 초 모델의 혼동 행렬을 살펴보면, Empty(440 건 정답), Standing(454 건 정답), Moving(531 건 정답) 세 가지 레이블 모두에서 고르게 안정적인 예측 성능을 확보한 것을 확인할 수 있다.

아래는 실시간 모니터링 터미널 화면이다.

[시간]	raw_result	final_vote	p_empty	p_stand	p_move	ch	buffer
[17:15:30]	Moving	Moving	0.063	0.229	0.708	111	160/160
[17:15:31]	Moving	Moving	0.088	0.217	0.695	111	160/160
[17:15:31]	Moving	Moving	0.069	0.273	0.658	111	160/160
[17:15:32]	Moving	Moving	0.111	0.195	0.695	111	160/160
[17:15:32]	Moving	Moving	0.105	0.186	0.709	111	160/160
[17:15:33]	Moving	Moving	0.161	0.180	0.660	111	160/160
[17:15:33]	Moving	Moving	0.158	0.232	0.609	111	160/160
[17:15:34]	Moving	Moving	0.179	0.323	0.498	111	160/160
[17:15:34]	Standing	Moving	0.168	0.468	0.363	111	160/160
[17:15:35]	Standing	Moving	0.259	0.470	0.271	111	160/160
[17:15:35]	Standing	Standing	0.323	0.461	0.215	111	160/160
[17:15:36]	Empty	Standing	0.465	0.385	0.150	111	160/160
[17:15:37]	Empty	Standing	0.467	0.364	0.168	111	160/160
[17:15:37]	Empty	Empty	0.524	0.316	0.160	111	160/160
[17:15:37]	Empty	Empty	0.540	0.335	0.126	111	160/160

그림 28. 실시간 모니터링 터미널 화면

5. 중간 결과 및 향후 연구 방향

기존에 실험한 모델 모두 Moving 상태를 높은 정확도로 구분해 내었으나, Empty와 Standing과 같은 정적 상태 간의 미세한 신호 차이를 명확히 구분하는 데에는 한계를 보였다. 그러나 MINIROCKET 알고리즘은 이러한 정적 상태의 오분류 문제를 효과적으로 극복하며 실시간 추론 환경에서도 안정적이고 높은 정확도를 달성하였다.

향후 연구에서는 세 레이블 모두에서 좋은 성능을 보이는 MINIROCKET 모델을 주로 활용하여, 단순 상태 인식을 넘어 낙상(Fall) 레이블을 새롭게 추가한 데이터 수집 및 분류 실험을 진행할 계획이다. 이를 바탕으로 실시간 환경에서 대상자의 낙상 사고를 즉각적으로 감지하고, 지정된 시스템을 통해 자동으로 도움을 요청하는 실질적인 응급 모니터링 시나리오를 구현 및 검증할 것이다.

6. 구성원별 역할 및 과제 추진 계획

6.1 구성원별 역할

이름	역할
박진석	- ESP32 기반 CSI 데이터 송수신 시스템의 펌웨어 개발 - 실내 다중경로 및 LoS 환경에서 CSI 데이터를 수집·분석하여 송수신기 최적 배치 실험 수행 - MINIROCKET 기반 시계열 분류 모델을 적용 및 성능 검증
김민준	- CSI 데이터의 특징 분석 및 환경 잡음 제거를 위한 신호 처리 - CSI 데이터의 진폭 및 PSD(Power Spectral Density) 시각화 수행 - 진폭 및 PSD 특징을 활용한 임계치 기반 재실 탐지 모델 개발
홍정기	- ESP32 기반 CSI 송수신 시스템의 펌웨어 최적화 및 모듈화 - CSI 시계열 데이터를 활용한 재실 및 활동 인식 1D CNN 모델 개발 - XGBoost 기반 CSI 데이터 분류 모델 구축 및 파라미터 튜닝을 통한 성능 개선 - 실험 데이터셋 수집 시나리오 설계 및 데이터 수집 자동화 파이프라인 구축

표 4. 구성원별 역할

6.2 과제 추진 계획




그림 29. 과제 추진 계획

- 낙상 데이터 수집 및 모델 개선 (7월 3주차~8월 1주차)

기존 Empty, Standing, Moving 상태에 Fall 레이블을 추가하여 PBL실 에서 CSI 데이터를 수집하여 모델 학습 후 정확도를 높인다.

- 웹 앱 개발 (8월 2주차~3주차)

수신되는 CSI 패킷과 예측 결과를 웹에 전달하기 위한 통신 프로토콜을 도입한다.

- 테스트 (8월 4주차)

실제 환경에 송수신기를 배치하고 실시간 웹앱을 구동하여 낙상 감지 및 재실 여부 정확도를 테스트한다.

- 최종보고서 작성(9월 1주차~3주차)

7. 참고 문헌

- 모형근, 김승구, "WiFi CSI를 활용한 머신러닝 기반 신원 확인 시스템," 2020년도 한국학술대회 논문집, 2020, pp. 133-134.
- H. Lee, C. R. Ahn, and N. Choi, "Exploiting Multiple Receivers for CSI-Based Activity Classification Using A Hybrid CNN-LSTM Model," in The 1st ACM Workshop on Device-Free Human Sensing (DFHS 19), New York, NY, USA, Nov. 2019, pp. 18–21. doi: 10.1145/3360773.3360878.
- [ESP32 Wi-Fi Vendor Features](#)
- A. Dempster, D. F. Schmidt, and G. I. Webb, "MiniRocket: A Very Fast (Almost) Deterministic Transform for Time Series Classification," in *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (KDD '21)*, Aug. 2021, pp. 248–257, doi: 10.1145/3447548.3467231.
- F. Deng, E. Jovanov, H. Song, W. Shi, Y. Zhang, and W. Xu, "WILDAR: WiFi Signal-Based Lightweight Deep Learning Model for Human Activity Recognition," *IEEE Internet of Things Journal*, vol. 11, no. 2, pp. 2899-2908, 15 Jan. 2024, doi: 10.1109/JIOT.2023.3294004.