

WiFi 채널 상태 정보(CSI)를 활용한 사용자 상태 정보 추론



202255660 박진석 wlstjr298@pusan.ac.kr

202155527 김민준 21kimminjun@pusan.ac.kr

202055624 홍정기 bluefrog010516@pusan.ac.kr

지도교수 김태운

목 차

1. 서론	1
1.1. 연구 배경	1
1.2. 기존 문제점	1
1.3. 연구 목표	2
2. 연구 배경 지식	3
2.1. ESP32	3
2.2. PlatformIO	3
2.3. 802.11n 통신 규격 및 패킷 구조	5
2.4. OFDM	6
2.5. RSSI	8
2.6. 1D CNN	8
2.7. XGBoost	10
3. 연구 내용	11
3.1. CSI 데이터 송수신 및 시각화	11
3.1.1. 채널 필터 설정에 따른 진폭 특성 분석	11
3.1.2. 전력 스펙트럼 밀도(PSD) 기반 주파수 영역 분석	12
3.2. 임계치 기반 재실 유무 탐지	13
3.2.1. 실험 환경 구성	13
3.2.2. 특성 추출 및 임계치 설정	14
3.3. 신뢰성 있는 패킷 수집을 위한 환경 최적화	15
3.3.1. 최적 채널 탐색	15

3.3.2.	데이터 수집 효율 향상을 위한 통신 방식 개선	16
3.4.	딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지	18
3.4.1.	실험 환경 구성.....	18
3.4.2.	데이터 전처리 및 모델 학습	19
3.5.	머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지	20
3.5.1.	실험 환경 구성.....	20
3.5.2.	학습 데이터셋 수집.....	20
3.5.3.	데이터 전처리 및 모델 학습	20
3.6.	데이터셋 구성 확장	21
3.6.1.	2인 데이터셋 추가.....	21
3.6.2.	낙상 데이터셋 추가.....	22
3.7.	계층적 상태 정보 추론 모델	22
3.7.1.	데이터셋 구성.....	22
3.7.2.	재실 유무 판별 모델	23
3.7.3.	사용자 동작 분류 모델.....	24
3.8.	실시간 상태 모니터링 및 낙상 감지 시 긴급 통화 프로세스.....	25
3.9.	전체 시스템 구성도	27
4.	연구 결과 분석 및 평가	28
4.1.	임계치 기반 재실 유무 탐지 결과.....	28
4.2.	딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지 결과.....	29
4.3.	머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지 결과.....	31
4.4.	데이터셋 구성 확장 결과.....	33
4.4.1.	2인 데이터셋 추가 결과	33
4.4.2.	낙상 데이터셋 추가 결과	35

4.5.	계층적 상태 정보 추론 모델 결과.....	37
4.6.	윈도우 및 슬라이딩 사이즈에 따른 성능 평가	39
4.7.	재실 판별 모델 종료 조건 평가	40
5.	결론 및 향후 연구 방향	42
6.	구성원별 역할 및 개발 일정	43
6.1.	구성원별 역할	43
6.2.	개발 일정	44
7.	참고 문헌	45

1. 서론

1.1. 연구 배경

최근 인구 고령화와 가구 형태의 변화로 인해 독거노인 가구 비율은 증가하고 있다.




그림 1. 통계청, 「2000~2024년 독거노인가구 비율 추이」, 2025.

이러한 독거 노년층에게 가장 치명적인 위협은 실내 낙상 사고이다. 질병관리청의 통계에 따르면, 70세 이상 낙상 환자 비율은 2014년 17.1%에서 2024년 35.3%로 10년 만에 2.1배 급증했다. 특히 전체 낙상 사고의 43.6%가 거실, 화장실, 침실 등 일상적인 주거 공간 내에서 발생하는 것으로 나타났다. 고령층의 낙상은 외상성 뇌손상(52.4%)이나 골절(39.4%) 등 중증 외상으로 직결된다. 따라서 홀로 거주하는 상태에서 실내 낙상이 발생할 경우, 즉각적인 구조 요청이 불가능하여 치명적인 결과로 이어질 위험이 크다.

따라서, 이러한 사고를 사전에 예방하기 위해, 실내 공간의 재질 여부와 활동 패턴을 실시간으로 파악하는 기술의 중요성이 점차 커지고 있다.

1.2. 기존 문제점

기존 실내 모니터링 시스템은 주로 카메라 센서를 활용한 영상 인식 방식을 채택해 왔다.

카메라는 사용자의 위치나 움직임, 자세 등의 정보를 직접적으로 획득할 수 있어 실내 상황을 직관적이고 높은 정확도로 분석할 수 있다는 장점이 있다. 그러나 주거 공간과 같이 개인의 일상적인 행동이 지속적으로 이루어지는 환경에서는 영상 데이터의 수집 및

저장 과정에서 사생활 침해에 대한 우려가 발생할 수 있다.

또한 카메라는 지속적인 영상 촬영 및 처리를 위해 일정 수준 이상의 전력을 지속적으로 소비하므로, 장시간 운영이 요구되는 실내 모니터링 시스템에서는 전력 소비 측면에서도 한계가 존재한다.

따라서 사용자의 행동 및 실내 상태를 모니터링하면서도 영상과 같은 민감한 개인정보의 수집을 최소화하고, 장시간 운용 시 전력 소비를 줄일 수 있는 비영상 기반 센싱 기술의 필요성이 높아지고 있다.

1.3. 연구 목표

본 연구의 목표는 우선 카메라와 같은 시각적 센서에 의존하지 않으면서도 사생활 침해 문제를 최소화하고, 실내 인원의 재실 여부와 활동 상태를 실시간으로 감지할 수 있는 비접촉·비시각적 공간 인지 기술을 개발하는 것이다. 이를 위해 실내에서 발생하는 사용자의 움직임에 따른 WiFi 신호의 변화를 분석하고, 수집된 신호로부터 인원의 존재 여부와 활동 상태를 판단할 수 있는 실시간 상태 인식 시스템을 구축하고자 한다.

또한 장시간 운용이 요구되는 주거 환경을 고려하여, 영상 정보와 같은 민감한 개인정보를 직접 수집하지 않으면서도 지속적인 모니터링이 가능한 센싱 환경을 구현하는 것을 목표로 한다. 특히 실내 인원의 상태를 단순히 재실 여부로 구분하는 데 그치지 않고, 세부적인 활동 상태(Empty, Standing, Moving, Lying)까지 구분함으로써 보다 정밀한 실내 상황 인지가 가능하도록 하고자 한다.

최종적으로는 이러한 실내 상태 인지 기술을 바탕으로 독거노인과 같은 1인 취약 계층 가구에서 발생할 수 있는 낙상과 같은 치명적인 응급 상황을 효과적으로 감지할 수 있는 실시간 모니터링 환경을 구축하는 것을 목표로 한다. 특히 인원의 자세 및 움직임 변화와 함께 추가적인 음성 정보를 활용하여 이상 상황을 판단하고, 응급 상황 발생 시 신속한 대응으로 이어질 수 있는 신뢰성 높은 모니터링 시스템을 구현하고자 한다.

2. 연구 배경 지식

2.1. ESP32

본 시스템은 송신기와 수신기를 각각 ESP32로 구성하여 1:1 통신 환경에서 CSI 데이터를 수집하도록 설계하였다. 사용된 ESP32의 상세 모델은 ESP32-DEVKIT V4(WROOM-32E)이다. 이는 2.4GHz 대역의 IEEE 802.11b/g/n Wi-Fi와 Bluetooth 4.2를 지원하며 34개의 GPIO 핀과 SPI, UART, I2C 등의 통신 인터페이스를 제공한다.

일반적인 Wi-Fi 통신은 응용 계층의 데이터가 전송 계층(TCP/UDP)과 네트워크 계층(IP)을 거치면서 각 계층의 헤더가 추가되어 통신 오버헤드가 발생한다. 반면, 본 시스템에 적용된 ESP-NOW 프로토콜은 TCP/IP 기반의 연결 절차를 사용하지 않고 IEEE 802.11의 전용 프레임을 이용하여 데이터를 전송하는 방식을 사용한다. 이를 통해 상위 계층의 프로토콜 처리 및 패킷 캡슐화에 따른 오버헤드를 줄일 수 있으며, 상대적으로 낮은 지연 시간의 패킷 송수신 환경을 구성하여 CSI 데이터 수집에 활용하였다.




그림 2. [ESP32-DevKitC V4 with ESP32-WROOM-32E](#)

2.2. PlatformIO

PlatformIO는 임베디드 시스템 및 IoT 장치의 펌웨어 개발을 지원하는 통합 개발 환경이다. 다양한 개발 프레임워크와 하드웨어 플랫폼을 하나의 프로젝트 환경에서 관리할 수 있으며, 라이브러리 의존성 관리, 프로젝트 빌드 및 펌웨어 업로드, 보드 및 개발 환경 설정 등의 기능을 제공한다. 이를 통해 임베디드 펌웨어 개발 과정에서 발생할 수 있는

환경 설정의 복잡성을 줄이고, 반복적인 실험과 테스트를 위한 개발 환경을 체계적으로 구성할 수 있다는 장점이 있다.

본 시스템에서는 ESP32 기반의 송신기와 수신기를 구현하고, ESP-NOW 통신 및 CSI 수집과 관련된 Wi-Fi 기능을 제어하기 위해 PlatformIO 환경을 사용하였다. 또한 프로젝트에 필요한 라이브러리와 보드 설정을 통합적으로 관리하여 송·수신기의 펌웨어를 동일한 개발 환경에서 작성하고 수정할 수 있도록 구성하였다.




그림 3. PlatformIO IDE

2.3. 802.11n 통신 규격 및 패킷 구조

ESP-NOW 프로토콜을 사용하는 환경에서 유의미한 CSI 데이터를 획득하기 위해서는 송신기의 통신 프로토콜을 802.11n으로 설정하는 것이 중요하다. 802.11n 규격은 직교 주파수 분할 다중 접속(OFDM) 방식을 통해 64개의 서브캐리어를 사용한다. 특히 물리 계층 프레임 내에 다중 안테나(MIMO) 환경의 채널 추정을 위해 고안된 HT-LTF 구간을 포함하므로, 정밀한 공간 자원 분석이 가능하다.




그림 4. [802.11n PPDU\(Physical layer Protocol Data Unit\)](#)

송신기에서 전송된 802.11n 전파는 시간에 따라 위 그림과 같이 여러 필드로 전송되며 수신기는 각 필드를 다음과 같은 단계로 처리하여 CSI를 도출한다.

- L-STF, L-LTF, L-SIG (Legacy Field)

IEEE 802.11a/g 등 기존 무선 규격과의 호환성을 확보하고 프레임의 검출 및 동기화를 수행하기 위해 포함되는 레거시 필드이다. 본 연구에서는 802.11n의 HT-LTF 기반 CSI 분석을 주요 대상으로 하므로, 수신기 펌웨어의 `l1tf_en = false` 설정을 통해 L-LTF 기반 CSI의 수집을 비활성화하고 HT-LTF 기반 CSI를 중심으로 분석하였다.

- HT-SIG (High Throughput Signal Field)

해당 패킷의 변조 방식과 물리적 제원이 명시된 구간이다. 송신기 측 펌웨어에서 설정한 대역폭과 제어 전송 속도인 MCS0 정보가 포함되어 있다. CSI 데이터 수집 시 패킷 손실을 최소화하고 신호의 안정성을 확보하기 위해 BPSK 기반의 가장 보수적인 변조 방식인 MCS0을 적용하였으며 수신기는 이를 디코딩하여 후속 필드 해석의 기준으로 삼는다.

- HT-STF (High Throughput Short Training Field)

HT-LTF 신호를 정확하게 획득하기 위한 타이밍 동기화를 수행하는 구간이다.

- HT-LTF (High Throughput Long Training Field)

HT-LTF는 수신기에서 채널 응답을 추정하기 위해 사용되는 기준 신호 구간이다. 송신된 기준 신호는 전파가 공간을 이동하는 과정에서 다중 경로 페이딩과 잡음 등의 영향을 받아 진폭 및 위상이 변화한다. 수신기 물리 계층에서는 수신 신호와 사전에 정의된 기준 신호의 관계를 이용하여 각 주파수 성분에 대한 복소수 채널 응답을 추정한다.

- Data Field

MAC 계층에서 전달되는 실제 전송 데이터가 포함되는 구간으로, MAC 헤더와 프레임 페이로드 등의 정보가 전송된다. 수신기는 수신된 프레임의 MAC 주소 및 관련 정보를 확인하여 분석 대상 패킷을 식별한다.

2.4. OFDM

수신 안테나를 통해 수신된 HT-LTF 신호는 시간 영역의 연속적인 신호로 입력된다. OFDM 기반의 무선 통신에서는 수신된 시간 영역 신호에 대해 FFT를 적용하여 주파수 영역의 신호로 변환하며, 이를 통해 각 부반송파별 신호 성분을 분리할 수 있다. 본 시스템의 ESP32 수신기는 이러한 OFDM 신호 처리 과정에서 획득된 CSI(Channel State Information)를 펌웨어의 CSI 콜백 함수인 `void csi_callback(void *ctx, wifi_csi_info_t *info)`를 통해 전달받으며, `info->buf`에는 각 부반송파에 대한 채널 정보가 [허수부, 실수부]의 형태로 저장된다.

802.11n에서는 20 MHz 대역폭에 64-point FFT를 적용하여 OFDM 심볼을 구성하며, 각 부반송파를 통해 주파수 영역의 채널 정보를 표현할 수 있다. CSI는 이러한 각 부반송파에서의 채널 응답을 나타내며, 무선 신호가 송신기에서 수신기로 전파되는 과정에서 발생하는 진폭과 위상의 변화를 포함한다. 따라서 CSI를 이용하면 사람의 움직임이나 주변 환경 변화에 따른 무선 채널의 변화를 주파수 영역에서 분석할 수 있다.

아래 그림은 802.11n 20 MHz OFDM 채널에서 사용되는 부반송파의 물리적 스펙트럼 배치 구조를 나타낸다.




그림 5. 802.11n OFDM 서브캐리어 구조

CSI 데이터는 각 서브캐리어의 채널 응답을 복소수 형태로 나타낸다. 각 채널 응답은 부호 있는 8비트 정수로 표현되는 두 개의 성분으로 구성되며, 이 값들은 하나의 복소수 채널 응답을 이루어 원시 CSI 버퍼에 저장된다.

802.11n HT20의 서브캐리어는 스펙트럼상의 위치에 따라 데이터 서브캐리어, 파일럿 서브캐리어, Null 서브캐리어로 구분된다. 데이터 서브캐리어는 실제 데이터 전송에 사용되는 부반송파이며, 파일럿 서브캐리어는 수신 신호의 동기 및 채널 추정 등을 위한 기준 신호로 사용된다. Null 서브캐리어는 데이터 전송에 사용되지 않는 부반송파이다.

PHY standard	Total Subcarriers	Pilot Subcarriers	Null Subcarriers
802.11n, 20 MHz	[-32, 31]	-21, -7, 7, 21	[-32, -29], [0], [29, 31]

표 1. 802.11n 20MHz 서브캐리어 인덱스

ESP32 물리 계층에서 고속 푸리에 변환 직후 출력되는 원시 데이터 버퍼의 배열 순서는 위 표에 명시된 인덱스 순서와 일치하지 않는다.

하드웨어의 출력 특성상 중심 주파수와 양의 주파수 대역이 배열 앞단에 배치되고 음의 주파수 대역이 뒷단으로 밀려나 순서가 뒤섞여 있기 때문이다.

따라서 수집된 CSI 데이터를 시각화하거나 머신러닝 모델의 특성 데이터로 온전히 활용하기 위해서 이후 데이터 전처리 과정에서 fftshift 연산을 수행하여 배열의 순서를 연속적인 물리적 스펙트럼 오름차순으로 재정렬하는 과정을 추가하였다.

2.5. RSSI

RSSI는 수신된 무선 신호의 전체적인 절대 강도를 나타내는 지표이다. 재실 상태 중 사람이 정지해 있는 Standing의 경우, 사람이 송신기와 수신기 사이의 가시선(Line-of-Sight, LoS) 상에 위치하거나 그 주변에 서있는 경우가 존재한다. 이때 사람에 의해 신호가 감쇠되는 현상이 발생하며, 이는 전체 수신 신호 강도에 변화를 일으킨다.

CSI 진폭의 미세한 시간적 변동성만으로는 재실 상태를 높은 확률로 구별하는 데 한계가 존재한다. 따라서 두 상태의 분류를 명확히 하고자 RSSI 값을 몇차례 실험 이후에 추가적인 특성으로 도입하였다.

2.6. 1D CNN

1D CNN에서 CNN은 Convolutional Neural Network(합성곱 신경망)의 약자로, 이미지 처리와 패턴 인식에 사용되는 인공신경망의 한 종류이다.

1D CNN은 시계열 데이터와 같은 1차원 축을 따라 배열된 순차적 데이터로부터 시간적 흐름에서의 패턴 특징을 추출하여 학습하고, 2차원 이미지를 학습할 수 있는 2D CNN은 픽셀들로 이루어진 이미지 데이터의 공간적 특징 정보를 격자 상에서 추출하여 학습한다.

학습을 위해 CNN은 크게 합성곱층(Convolutional Layer), 풀링층(Pooling Layer), 밀집층(Fully Connected Layer)으로 구성되어 있다.




그림 6. [Typical architecture of 1D Convolution Neural Networks \(1D-CNN\).](#)

본 실험에서 사용될 1D CNN의 합성곱 층(Convolutional Layer)에서는 1차원 배열 형태의 입력 데이터 위를 커널(Kernel)이라 불리는 필터가 순차적으로 슬라이딩하며 합성곱 연산을 수행하여 새로운 특성 맵(Feature Map)을 생성한다. 이러한 특성 맵은 입력 데이터에 내재된 시간적 패턴이 추출 및 요약된 특징을 가지며, 이후 풀링층과 밀집층을 거쳐 최종적인 데이터 분류에 이용된다. 아래 그림은 이 과정을 시각적으로 나타낸 것이다.




그림 7. [1D CNN의 1차원 슬라이딩 연산 및 특성 맵\(Feature Map\) 추출 과정](#)

다음으로, 풀링 층(Pooling Layer)은 합성곱 층에서 추출된 특성 맵의 크기를 줄이는 역할을 한다. 크기를 줄이는 방법으로는 지정된 구간 내에서 최댓값을 추출하는 최대 풀링(Max Pooling)이나 평균값을 계산하는 평균 풀링(Average Pooling) 방식이 사용된다. 이를 통해 모델의 연산 비용을 줄이면서도 데이터의 중요한 특징은 보존할 수 있다.

마지막으로, 밀집층(Fully Connected Layer)은 추출된 특성 맵을 바탕으로 최종 출력 결과를 생성하는 역할을 한다. 이를 위해 먼저 평탄화 층(Flatten Layer)을 거쳐 특성 맵들을 하나의 긴 1 차원 배열로 평탄화한다. 밀집층은 이렇게 펼쳐진 지역적 특징들을 한 번에 입력으로 받아 데이터의 전체적인 패턴을 종합하고, 출력층을 통해 최종 예측값을 산출한다. 모델의 학습 과정에서는 이 최종 예측값과 실제 정답 간의 오차를 계산하며, 이를 최소화하는 방향으로 밀집층의 노드와 합성곱 층의 커널을 포함한 모델 내부의 가중치를 점진적으로 최적화해 나간다.

2.7. XGBoost

XGBoost 는 eXtreme Gradient Boosting 의 약자로, 결정 트리(Decision Tree)를 기반으로 하는 머신러닝 알고리즘이다.

XGBoost 는 여러 개의 약한 예측 모델인 결정 트리를 순차적으로 생성하여 학습한다. 이때 이전 트리가 잘못 예측한 오차에 가중치를 부여하고, 다음 트리가 이 오차를 보완하는 방향으로 학습을 진행하는 Gradient Boosting 방식을 사용한다.

이 모델은 데이터를 분할하며 정답을 찾아가는 여러 개의 결정 트리를 생성하고, 각 트리의 예측 결과를 결합하여 최종 분류값을 산출한다. 학습 과정에서는 손실 함수(Loss Function)를 최소화하는 방향으로 트리의 구조와 가중치를 점진적으로 최적화하며, 모델의 과적합을 방지하기 위한 정규화 기법을 내장하고 있어 뛰어난 예측 성능과 일반화 능력을 제공한다.




그림 8. [Simplified structure of XGBoost.](#)

3. 연구 내용

3.1. CSI 데이터 송수신 및 시각화

3.1.1. 채널 필터 설정에 따른 진폭 특성 분석

이전에 설계한 ESP-NOW 기반의 통신 환경을 통해 패킷의 CSI 데이터를 수집하고 서브캐리어에 대한 주파수 영역의 진폭을 ESP32 펌웨어의 CSI 설정 구조체(wifi_csi_config_t)에 포함된 내부 대역 필터링 옵션인 channel_filter_en의 활성화 여부에 따라 시각화한 결과를 분석하였다. 채널 필터는 인접 채널 간섭 및 대역 외 잡음을 억제하기 위한 ESP32 하드웨어 내부의 디지털 필터이다.

서브캐리어의 진폭은 수신된 CSI 버퍼의 허수부(Q, Quadrature)와 실수부(I, In-phase)를 이용하며, 각 성분의 제곱을 더한 후 제곱근을 취하는 방식으로 계산된다.




그림 9. 채널 필터 활성화 시 서브캐리어들의 원시 진폭 그래프

채널 필터를 활성화한 상태에서 추출된 진폭 그래프는 필터가 서브캐리어 간의 급격한 변화율을 억제하여 진폭 그래프가 전체적으로 평탄화되거나 부드러운 곡선 형태로 나타났다. 이 설정은 수신기 입장에서 신호의 신뢰성을 높이고 잡음을 제거하는 데는 유리하지만, CSI 센싱 관점에서는 단점으로 작용한다. 공간 변화에 의해 발생한 유의미한 전파 왜곡을 하드웨어가 통신 노이즈로 간주하여 깎아내리기 때문이다.

다음으로, 채널 필터를 비활성화 하였을 때의 그래프이다.




그림 10. 채널 필터 비활성화 시 서브캐리어들의 원시 진폭 그래프

위 그래프는 주파수 대역별 진폭의 변동성이 크고, 서브캐리어 간의 미세한 굴곡이 선명하게 나타난다. 하드웨어가 평탄화를 위해 개입하지 않았기 때문에, 사람의 미세한 움직임이나 위치 변화 등 공간의 물리적 변화가 진폭 파형에 즉각적이고 예민하게 반영된다. 따라서 환경 감지나 행동 인식 머신러닝 모델을 학습시키기 위한 특성 데이터 수집에 적합한 상태로 판단하였다.

따라서 본 프로젝트의 목적에 부합하는 데이터를 수집하기 위해서는, 수신기 측 펌웨어에서 명시적으로 `channel_filter_en = false`로 설정하여 하드웨어의 신호 왜곡 개입을 차단하였다.

3.1.2. 전력 스펙트럼 밀도(PSD) 기반 주파수 영역 분석

앞서 시간 축에서 확인한 CSI 진폭의 변화량은 직관적이지만 특정 움직임의 패턴이나 주기를 정량화하기에는 한계가 있다. 따라서 특정 움직임의 패턴을 확인하기 위해 수집된 시간 데이터에 스펙트럼 분석을 적용하여 주파수 영역에서의 에너지 분포를 시각화하고 분석하였다.

이후 진행할 임계치 기반 재실 유무 탐지 시스템에서는 표본화 주파수인 패킷 송수신 속도는 10 Hz로 설정되어 있다. 나이퀴스트 이론에 따르면, 시스템이 왜곡 현상 없이 온전히 복원할 수 있는 최대 유효 주파수는 표본화 주파수의 절반이다. 따라서 주파수 분석

대역을 0~5 Hz 구간으로 설정 후 전력 스펙트럼 밀도를 시각화하였다.




그림 11. 5초 윈도우 기반 서브캐리어의 Periodogram

회색 선은 서브캐리어 각각이 가지는 주파수별 에너지 분포를 나타낸다. 서브캐리어마다 중심 주파수 파장이 다르므로, 동일한 공간적 변화에 대해서도 각기 다른 다중 경로 페이딩 응답을 보여 다양한 형태의 스펙트럼이 겹쳐서 나타난다. 붉은 색 선은 52개 서브캐리어의 주파수별 에너지 평균 값이다.

실시간 시각화 분석 결과, 통신 공간 내 사람의 움직임 여부에 따라 주파수 대역별 에너지 분포가 움직임 발생 시 0 Hz보다 큰 유효 주파수 대역 전반에서 신호 에너지가 확연히 상승하였고, 정지 시 변화 폭이 크게 줄어들며 주파수가 0 Hz에 가까운 저주파 대역에 에너지가 집중되는 것을 확인하였다.

이처럼 대상의 동적, 정적 상태에 따라 CSI 진폭 및 특정 주파수의 에너지가 뚜렷한 차이를 보인다는 점을 확인하였다. 따라서 진폭과 주파수 에너지는 임계치 기반 재실 유무 탐지를 설계하기 위한 판별 지표로 활용되었다.

3.2. 임계치 기반 재실 유무 탐지

3.2.1. 실험 환경 구성

데이터 수집 및 실시간 분석 알고리즘은 Python 환경(pyserial, scipy, numpy)을 기반으로 구축되었다. ESP32 수신기, 수신기와 연결된 노트북간의 시리얼 통신을 통해 초당 약 10

회의 샘플링 속도로 물리 계층의 CSI 패킷을 수집하도록 환경을 구성하였다.

아래 사진은 ESP32 송수신기가 1:1로 설치된 실제 환경이다.



그림 12. 실제 환경 구성. PBL실2(301-2호)

ESP32가 반환하는 64개의 서브캐리어 원시 배열 중 802.11n(HT20) 규격에 맞추어 상/하 위 가드 밴드, DC 성분의 중심 주파수, 파일럿 서브캐리어를 인덱스 기반으로 제거하는 데이터 전처리를 수행하였다. 그 결과, 공간의 물리적 변화를 가장 민감하게 반영하는 52개의 유효 데이터 서브캐리어 정보만을 추출하여 분석에 활용하였다.

3.2.2. 특성 추출 및 임계치 설정

사람의 움직임이나 위치 변화는 다중 경로 파편화를 유발하며, 이는 수신된 CSI의 진폭 변화로 나타난다. 해당 알고리즘은 5초 분량인 50개의 패킷을 하나의 슬라이딩 윈도우로 묶어 다음 두 가지 지표를 추출하였다.

- **진폭의 분산**: 수신기와 송신기 간의 거리나 장애물의 배치 등 측정 환경이 달라지면 수신되는 CSI의 절대적인 기저 진폭 수준이 크게 변하게 된다. 이러한 DC Offset 차이를 배제하고, 오직 사람의 움직임으로 인해 발생하는 진폭의 순수한 변화량에만 집중하기 위해 윈도우 내 데이터의 분산을 계산하였다. 분산의 연산 과정에는 평균 중심화가 포함 되므로 절대적인 진폭의 높낮이는 무시되며, 정적 상태일 때보다 움직임이 발생할 때 파형의 요동이 커지면서 분산 값이 급격히 상승 한다.

- **1~4 Hz 대역의 주파수 에너지**: 사람이 걷거나 팔을 흔드는 등의 일반적인 움직임은 주

파수 영역에서 주로 1~4 Hz 대역에 집중된다. 이를 수치화하기 위해 시간 축의 진폭 윈도우를 Periodogram 함수를 통해 주파수 영역으로 변환하고, 1~4 Hz 대역에 분포하는 전력 스펙트럼 밀도의 총합을 구하였다. 이 대역을 벗어나는 고주파 신호는 하드웨어 노이즈로 간주하여 필터링하였다.

추출된 두 가지 지표를 바탕으로, 실시간 재실 유무를 판별하기 위한 임계치는 진폭 분산은 26.0, 1~4 Hz 에너지는 350.0 으로 설정하였다.

슬라이딩 윈도우 연산 시마다 위 두 가지 조건 중 하나라도 임계치를 초과할 경우 해당 시점의 상태를 재실(Presence = 1)로 판별하며, 두 지표 모두 임계치 미만일 경우 빈 방(Empty = 0)으로 판별한다. 이 결과는 추출된 특성 값들과 함께 타임스탬프 기준으로 CSV 파일에 실시간 누적 기록된다.

3.3. 신뢰성 있는 패킷 수집을 위한 환경 최적화

3.3.1. 최적 채널 탐색

동일한 통제 환경에서 패킷 데이터를 수집하더라도, 시간의 경과 및 주변 환경 요인에 따라 수신 데이터의 변동성이 크게 나타나는 문제가 이전 임계치 기반 재실 탐지 모델에서 발생하였다. 이러한 신호의 불안정성은 수집된 데이터의 신뢰성을 저하시키는 주요 원인이다. 따라서 외부 노이즈 및 전파 간섭을 최소화하고, 데이터 변화량이 가장 적은 안정적인 상태를 확보하기 위해 다음과 같이 수집 환경 최적화를 수행하였다. 최적화를 수행한 공간은 PBL실2(301-2호) 이다.

본 프로젝트에 사용되는 ESP32 모듈은 2.4GHz 대역(802.11 b/g/n)을 지원하므로, 5GHz 대역의 스캔 결과값을 배제하고 2.4GHz 대역에 한정하여 분석하였다. 아래 그림은 맥북 에어(M1)의 Wireless Diagnostics 내장 앱을 사용하여 주변 무선 네트워크 환경을 스캔한 결과이다. 해당 스캔 데이터를 분석한 결과, 주변 공유기와의 전파 중첩 및 간섭이 가장 적은 11번 채널이 데이터 수집을 위한 최적의 통신 채널로 확인되었다.

Summary	Network Name	BSSID	Security	Protocol	RSSI	Noise	Channel	Band	Width	Country
Total 22		70:bd:96:98:62:23	Open	802.11ax	-58	-91	6	2.4GHz	20MHz	KR
2.4GHz Count 6	305_2.4GHz	36:c5:99:8f:0e:d8	WPA2 Personal	802.11be	-82	-93	6	2.4GHz	20MHz	KR
5GHz Count 16	[LG_CeilingCassette A/C]23a3	16:7f:67:bc:23:a3	WPA2 Personal	802.11n	-91	-91	11	2.4GHz	20MHz	US
6GHz Count 0	DdIM	58:86:94:81:07:fc	WPA2 Personal	802.11ax	-89	-92	7	2.4GHz	40MHz	KR
Current Channel Count 2	iptime	b0:38:6c:2f:04:6c	Open	802.11ax	-81	-92	2	2.4GHz	40MHz	KR
Best 2.4GHz 11	pnucse_6202(2G)	70:5d:cc:93:2c:5c	Open	802.11n	-80	-92	5	2.4GHz	40MHz	-
Best 5GHz 161		30:c5:99:8f:0e:d9	WPA2 Personal	802.11be	-92	-89	40	5GHz	160MHz	KR
	305_5GHz	36:c5:99:8f:0e:d9	WPA2 Personal	802.11be	-93	-89	40	5GHz	160MHz	KR
	eduroam	70:bd:96:98:2b:ef	WPA/WPA2 Enterprise	802.11ax	-48	-91	44	5GHz	40MHz	KR
	eduroam	70:bd:96:98:62:2f	WPA/WPA2 Enterprise	802.11ax	-53	-91	116	5GHz	40MHz	KR
	eduroam	70:bd:96:98:63:0f	WPA/WPA2 Enterprise	802.11ax	-91	-91	48	5GHz	40MHz	KR
	eduroam	94:0d:4b:ea:65:07	WPA/WPA2 Enterprise	802.11ax	-92	-92	157	5GHz	40MHz	KR
	eduroam	94:0d:4b:ea:65:0f	WPA/WPA2 Enterprise	802.11ax	-92	-91	36	5GHz	40MHz	KR
	eduroam	94:0d:4b:ea:7a:27	WPA/WPA2 Enterprise	802.11ax	-83	-91	157	5GHz	40MHz	KR
	eduroam	94:0d:4b:ea:7a:2f	WPA/WPA2 Enterprise	802.11ax	-90	-91	48	5GHz	20MHz	KR
	PNU-WiFi	70:bd:96:98:2b:...	Open	802.11ax	-48	-91	44	5GHz	40MHz	KR
	PNU-WiFi	70:bd:96:98:62:2e	Open	802.11ax	-53	-91	116	5GHz	40MHz	KR
	PNU-WiFi	70:bd:96:98:63:0e	Open	802.11ax	-91	-91	48	5GHz	40MHz	KR
	PNU-WiFi	94:0d:4b:ea:65:06	Open	802.11ax	-93	-92	157	5GHz	40MHz	KR
	PNU-WiFi	94:0d:4b:ea:65:0e	Open	802.11ax	-91	-89	36	5GHz	40MHz	KR
	PNU-WiFi	94:0d:4b:ea:7a:26	Open	802.11ax	-83	-91	157	5GHz	40MHz	KR
	PNU-WiFi	94:0d:4b:ea:7a:2e	Open	802.11ax	-90	-91	48	5GHz	20MHz	KR

그림 13. Wireless Diagnostics 스캔 결과

3.3.2. 데이터 수집 효율 향상을 위한 통신 방식 개선

초기 시스템은 10Hz의 수집 주기 환경에서 수신된 CSI 데이터를 ASCII 문자열 포맷 ("CSI_DATA, -13, [12, -4, ...]")으로 변환하여 시리얼 통신을 통해 전처리 프로세스로 전송하였다. 그러나 수집 주기를 40Hz로 4배 상향하고, 통신 속도를 921600 bps로 높이는 과정에서 ESP32 수신기의 오버헤드 및 시리얼 버퍼 오버플로우로 인한 패킷 유실을 발견하였다. 이는 빠른 데이터 수집 주기 대비 텍스트 변환 및 직렬화 과정이 갖는 비효율성 때문이었다.

이를 해결하고 40Hz의 고속 패킷 스트리밍을 안정적으로 지원하기 위해, 수신기의 데이터 처리 및 전송 아키텍처를 다음과 같이 최적화하였다.

- 문자열 방식에서 바이너리 페이로드 전송으로 전환

기존의 Serial.print()를 이용한 ASCII 문자열 전송 방식은 데이터 크기를 크게 늘린다. 예를 들어, 1바이트의 음수 데이터('-128')를 문자열로 전송하면 ','를 포함해 5바이트가 소모된다. 이를 해결하기 위해 수신된 원본 CSI 데이터를 문자열로 변환하지 않고, 메모리 복사(memcpy)를 통해 바이너리 형태 그대로 버퍼(uint8_t buf)에 담아 Serial.write()로 일괄 전송하도록 수정하였다. 이를 통해 송신 페이로드의 크기를 1/3 이하로 대폭 압축하였으며, ESP32의 텍스트 파싱 오버헤드를 제거하여 921600 bps 대역폭의 효율을 높일 수 있

었다.

- FreeRTOS 큐를 활용한 비동기 데이터 파이프라인 구축

기존 코드에서는 Wi-Fi 수신 인터럽트 콜백 함수 내에서 직접 시리얼 출력을 수행하여, 시리얼 전송이 지연될 경우 수신 처리가 병목을 겪는 구조적 한계가 있었다. 따라서 최적화된 구조에서는 콜백 함수 내에서 시간 소모가 큰 I/O 작업을 배제하고, 수신된 데이터를 FreeRTOS의 xQueueSendFromISR을 통해 내부 큐에 즉시 적재만 하도록 분리하였다. 이후 메인 루프(loop())에서 비동기적으로 큐를 읽어 시리얼 포트에 전송함으로써, 고주파수(40Hz) 수신 환경에서도 Blocking 없이 실시간 데이터 수집이 가능하도록 시스템 안정성을 확보하였다.

- 데이터 무결성 검증 및 동기화 헤더 도입

고속의 바이너리 통신에서는 데이터 프레임의 경계를 인식하기 어려우므로 수신 측의 전처리 프로세스에서 패킷 밀림 현상이 발생할 수 있다. 이를 방지하기 위해 전송 버퍼의 선두에 고정된 동기화 바이트(SYNC0: 0xAA, SYNC1: 0xBB)와 데이터 길이를 9 배치하였다. 또한, 타임스탬프, 시퀀스 번호, 그리고 페이로드 전체에 대한 XOR 체크섬 필드를 추가하여, 고속 통신 환경에서도 오차나 유실 위치를 정확히 감지하고 필터링할 수 있는 프로토콜을 완성하였고 이는 전처리 프로세스에서 모듈로 사용한다.

```
memcpy(&buf[idx], &seq_num, 2); idx += 2;
memcpy(&buf[idx], &ts_us, 4); idx += 4;
buf[idx++] = (uint8_t)rssi;
memcpy(&buf[idx], &length, 2); idx += 2;
memcpy(&buf[idx], item.csi_data, length);
idx += length;

// 체크섬 계산 (파이썬 코드: offset 2 부터 HEADER_LEN+length-1 까지 XOR)
uint8_t cs = 0;
for (int i = 2; i < idx; i++) {
    cs ^= buf[i];
}
buf[idx++] = cs;

// 완성된 이진 프레임 전송
Serial.write(buf, idx);
```

그림 14. ESP32 수신기 펌웨어 1바이트 XOR 체크섬 코드

921600bps 의 고속 시리얼 통신에서 대량의 CSI 데이터를 실시간으로 전송하기 위해 1 바이트 XOR 누적 체크섬을 사용한다. 연산 부하 감소와 전송 지연 최소화를 우선시하여 실시간 데이터 처리량을 확보한 대안이다.

3.4. 딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지

3.4.1. 실험 환경 구성

환경 변화에 따른 변수를 배제하기 위해 송수신기 배치 및 통신 공간 환경(PBL실2)은 앞 4.3절의 임계치 기반 탐지 실험과 동일하게 유지하였으나, 샘플링 주파수와 baud rate는 각각 40 Hz와 921600으로 변경하여 구성하였다.

데이터는 피실험자 3명(A, B, C)을 대상으로, 서로 다른 3일에, 3가지 레이블에 대해 각각 5회씩 반복 측정하여 총 135개의 세션을 수집하였다. 이는 데이터 수집 과정에서 발생할 수 있는 시간적 환경 변화(온도, 외부 간섭 등)가 특정 피실험자나 레이블에 과적합되는 것을 방지하기 위함이며, 이를 위해 측정 순서 또한 무작위로 교차 배치하였다. 수집이 완료된 원시 데이터는 모델의 객관적인 성능을 평가하기 위해 학습(Train), 검증(Validation), 테스트(Test) 세트로 분할하였으며, 전체 세션의 구성은 아래 표와 같다.

데이터 분할	대상 피험자	분할별 총 세션 수	비율
Train	A, B (day1~3) + C (day1, day2)	96	약 71.1%
Validation	A, B (day1~3) + C (day1, day2)	24	약 17.8%
Test	C (day3)	15	약 11.1%

표 2. 데이터셋 수집 시나리오

또한 머신러닝 모델의 범용성과 강건성을 확보하기 위해 단일 행동의 반복 측정을 지양하고 레이블 내 세부 시나리오를 다양화했다. 데이터 수집 환경 변화와 관계없이 모델 학습을 위한 데이터 전처리 방식은 동일하게 적용된다. Standing 레이블은 단순히 가만히 서 있는 동작을 넘어 측정 시마다 피실험자가 바라보는 방향을 반대로 전환하고 서 있는 위치를 변경함으로써 인체의 방향성과 위치 변화에 따른 전파 단면적 변화를 학습에 반영했다. Moving 레이블 또한 단순 보행에 국한하지 않고 방 내부를 U자 형태로 도는 동선, 직선으로 왕복하는 동선, 불규칙하게 걷는 동선의 세 가지 서로 다른 패턴을 구성하

였다.

3.4.2. 데이터 전처리 및 모델 학습

전처리 이전에 원본 세션 파일 단위로 학습, 검증, 테스트 세트를 약 8:1:1 비율로 분리하였다. 이후 각 파일의 원시 CSI 데이터(64개 서브캐리어)에 fftshift를 적용하고 노이즈 대역을 제거하고, 파일럿 서브캐리어는 포함하여 55개의 유효 서브캐리어를 추출한 뒤 진폭 데이터로 변환하였다.

연속적인 행동 패턴을 반영하기 위해 변환된 진폭 데이터에 슬라이딩 윈도우(크기 200, 슬라이드 40)를 적용하여 분할하였으며, 환경적 신호 편향을 제거하고자 각 윈도우 내부에서 서브캐리어별 Z-score 정규화를 독립적으로 수행하였다.

별도의 통계적 특징 추출 없이 시간의 흐름을 보존한 이 데이터는, 1D CNN 모델의 입력 규격에 맞추어 서브캐리어를 채널로 취급하는 (55, 200) 차원의 텐서로 최종 변환된다. 모델은 3단계의 깊이별 분리 합성곱을 통해 움직임 특징을 스스로 추출하며, 조기 종료 기법을 병행하여 과적합 없이 재실 상태(Empty, Standing, Moving)를 판별할 수 있게 학습시켰다. 아래 그림은 데이터 전처리 과정에서의 텐서 차원 변화를 요약한 것이다.




그림 15. 데이터 전처리 과정의 텐서 차원 변화

3.5. 머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지

3.5.1. 실험 환경 구성

이번 실험의 데이터 수집 환경 및 조건은 이전 1D CNN 방식과 동일하게 설정하였다. 수집 대상 레이블의 종류와 수는 Empty, Standing, Moving의 세 가지로 기존과 같으며, 송수신기의 배치 구조 또한 동일하게 유지하였다.

3.5.2. 학습 데이터셋 수집

40 Hz의 샘플링 주파수와 921600 baud rate 환경에서 수집되었고, 1D CNN 모델 학습에 활용한 총 135개의 세션 파일(.npz)을 별도의 변형 없이 XGBoost 모델 학습에도 그대로 사용하였다.

3.5.3. 데이터 전처리 및 모델 학습

데이터 누수 방지를 위한 세션 파일 단위의 데이터 세트 분리부터 유효 서브캐리어(55개) 추출, 진폭 변환, 슬라이딩 윈도우(크기 200, 슬라이드 40) 분할 및 Z-score 정규화까지의 기본 전처리 과정은 앞선 1D CNN 모델과 동일하게 수행되었다.

2 차원 시계열 배열을 그대로 학습하는 1D CNN과 달리 머신러닝 기반의 XGBoost 모델을 위해 추가적인 통계적 특징 추출을 진행하였다. 정규화가 완료된 각 윈도우(200, 55) 데이터에 대하여, 55개의 유효 서브캐리어 각각에 8가지 통계 지표(평균, 표준편차, 최댓값, 최솟값, 에너지, RMS, 왜도, 첨도)를 계산하였다. 결과적으로 단일 윈도우는 440 차원 (55, 8)의 1차원 특징 벡터로 압축된다.

이렇게 개별적으로 생성된 440차원의 특징 벡터 데이터셋은 다중 클래스 분류를 수행하는 XGBoost 모델의 입력으로 제공된다. 알고리즘은 입력된 440개의 특징을 기반으로 다수의 Decision Tree를 순차적으로 생성하며 재실 상태(Empty, Standing, Moving)를 판별하도록 학습되었다. 학습 과정에서는 검증 세트의 다중 로그 손실 지표를 지속적으로 모니터링하고 조기 종료를 적용하여 모델의 과적합을 방지하였다.

아래 그림은 데이터 전처리 과정에서의 텐서 차원 변화를 요약한 것이다.




그림 16. 데이터 전처리 과정의 텐서 차원 변화

3.6. 데이터셋 구성 확장

3.6.1. 2인 데이터셋 추가

기존 데이터셋은 실내에 한 명의 재실자만 존재하는 환경에서 수집된 데이터로, Empty, Standing, Moving 각 상태에 대해 45세션씩 구성되어 있었다. 본 연구에서는 실제 실내 환경에서 발생할 수 있는 다중 재실 상황을 고려하기 위해 2인 환경의 데이터를 추가로 수집하였다. 추가 데이터셋은 2인 Standing과 2인 Moving, 1인은 Standing 나머지 1인은 Moving 상태로 구성하였으며, 이를 기존 1인 데이터셋과 함께 학습 및 평가에 활용하여 재실 인원 증가에 따른 모델의 상태 추론 성능 변화를 확인하였다.

레이블	세션 수(세션 당 시간(초))	재실자 조합
Empty	45(60)	-
1 Standing	45(60)	A, B, C
1 Moving	45(60)	A, B, C
2 Standing	45(60)	AB, BC, CA
1 Standing, 1 Moving	45(60)	AB, BC, CA
2 Moving	45(60)	AB, BC, CA

표 3. 확장한 데이터셋 구성

3.6.2. 낙상 데이터셋 추가

기존 데이터셋의 다양성과 낙상 상황에 대한 데이터를 확보하기 위해 추가 데이터셋을 수집하였다. 기존 6개 레이블에서 2인에 관한 레이블 3개를 제외하고 2분 길이의 세션 9개를 추가로 수집하였다. 이에 따라 각 상태별 데이터는 기존 45세션에 9세션이 추가되어 총 54세션으로 구성하였다.

또한 실제 낙상 상황을 반영하기 위해 별도의 낙상 데이터를 수집하였다. 총 3명의 대상자별로 정지 상태에서 낙상하는 경우 10회와 움직이는 상태에서 낙상하는 경우 10회를 수행하였다. 따라서 대상자 1인당 총 20세션, 전체 3명에 대해 총 60세션의 낙상 데이터를 확보하였다. 낙상 데이터는 세션당 6초이다.

레이블	세션 수(세션 당 시간(초))	재실자 조합
Empty	9(120) + 45(60)	-
Moving	9(120) + 45(60)	A, B, C
Standing	9(120) + 45(60)	A, B, C
Fall	60(6)	A, B, C

표 4. 낙상 레이블을 추가한 데이터셋 구성

3.7. 계층적 상태 정보 추론 모델

본 시스템은 재실 여부(Empty, Occupied)를 먼저 판단하고, 사람이 있을 경우(Occupied) 세부 동작을 분류하는 2단계 계층적 구조로 이루어져 있다. 각 목적에 맞춰 서로 다른 두 가지 머신러닝/딥러닝 모델이 사용된다.

3.7.1. 데이터셋 구성

데이터셋의 레이블은 Empty, Standing, Lying, Moving으로 구성하였으며, 각 레이블은 1분 세션 45개와 2분 세션 18개로 총 63세션씩 구성하였다. 특히 새롭게 추가한 Lying 데이터는 재실자가 눕는 위치를 조금씩 변경해가며 수집하여 위치 변화에 따른 CSI 특성을 함께 반영할 수 있도록 구성하였다.

레이블	세션 수(세션 당 시간(초))	재실자 조합
Empty	45(60) + 18(120)	-
Moving	45(60) + 18(120)	A, B, C
Standing	45(60) + 18(120)	A, B, C
Lying	45(60) + 18(120)	A, B, C

표 5. Lying 레이블을 추가한 데이터셋 구성

Lying 레이블은 이후 소리 감지 결과와 함께 활용하여 낙상 판별에 사용된다.

3.7.2. 재실 유무 판별 모델

재실 여부 판별 모델은 빈 공간(Empty)과 사람이 있는 상태(Occupied)를 이진 분류하며, 1D CNN 아키텍처를 기반으로 한다. 10초 분량의 서브캐리어 채널 데이터(400패킷)를 입력받아, 크기가 다른 필터를 가진 3개의 합성곱 계층과 풀링 계층을 차례로 거친다.

이후 전역 평균 풀링과 과적합 방지를 위한 30% 비율의 드롭아웃을 적용한 뒤, 시그모이드 활성화 함수를 통해 최종 확률값을 출력한다.

```

x = tf.keras.layers.Conv1D(64, 7, padding="same", activation="relu")(inp)
x = tf.keras.layers.BatchNormalization()(x)
x = tf.keras.layers.MaxPooling1D(2)(x)
x = tf.keras.layers.Conv1D(128, 5, padding="same", activation="relu")(x)
x = tf.keras.layers.BatchNormalization()(x)
x = tf.keras.layers.MaxPooling1D(2)(x)
x = tf.keras.layers.Conv1D(128, 3, padding="same", activation="relu")(x)
x = tf.keras.layers.GlobalAveragePooling1D()(x)
x = tf.keras.layers.Dropout(0.30)(x)

```

그림 17. 합성곱 계층 및 풀링 계층 코드

이 모델은 이진 교차 엔트로피 손실 함수와 Adam 옵티마이저를 사용하여 학습하며, 데이터 불균형을 해소하기 위해 클래스별 가중치를 부여한다. 또한 검증 손실을 모니터링하여 학습률을 조정하고 조기 종료 기법을 적용하여 모델을 최적화한다.

```
callbacks = [
    tf.keras.callbacks.EarlyStopping(
        monitor="val_loss", patience=5, min_delta=1e-4, restore_best_weights=True),
    tf.keras.callbacks.ReduceLROnPlateau(
        monitor="val_loss", factor=0.5, patience=2, min_lr=1e-5, verbose=0),
]
```

그림 18. 조기 종료 코드

3.7.3. 사용자 동작 분류 모델

사용자 동작 분류 모델은 사람이 있다고 판별된 경우(Occupied) 눕기(Lying), 서 있기(Standing), 움직이기(Moving)의 3가지 상태로 세부 동작을 분류한다. 이 모델은 결정 트리 기반의 기법인 XGBoost를 기반으로 한다. 3초 분량의 윈도우에서 추출한 진폭 및 수신 신호 강도의 평균, 표준편차, 최댓값, 최솟값 등 다양한 통계적 특징을 입력 데이터로 활용한다.

```
def sc_stats(x):
    d = np.diff(x, axis=0)
    ad = np.abs(d)
    xmax, xmin = np.max(x, axis=0), np.min(x, axis=0)
    return np.concatenate([
        np.mean(x, axis=0), np.std(x, axis=0), xmax, xmin,
        np.median(x, axis=0), xmax-xmin,
        np.std(d, axis=0), np.mean(ad, axis=0), np.percentile(ad, 95, axis=0)
    ]).astype(np.float32)

def activity_feature(amp, rssi, baseline_rssi):
    dr = rssi.astype(np.float32) - float(baseline_rssi)
    rf = np.array(
        [np.mean(dr), np.std(dr), np.min(dr), np.max(dr), np.max(dr)-np.min(dr)],
        dtype=np.float32
    )
    return np.concatenate([sc_stats(amp), rf]).astype(np.float32)
```

그림 19. 입력 데이터 코드

트리 개수 350개, 최대 깊이 4, 학습률 0.05로 설정되며, 데이터와 피쳐 샘플링 비율을 각각 0.85로 두어 모델의 분산 효과를 얻는다. 히스토그램 기반의 트리 생성 방식과 다중 로그 손실 평가 지표를 활용하여 모델을 학습시킨다.

3.8. 실시간 상태 모니터링 및 낙상 감지 시 긴급 통화 프로세스

본 프로세스는 딥러닝/머신러닝 모델을 통해 판별된 사용자의 실시간 상태 데이터를 수신하여, 웹 대시보드에 표시하고 발생 시 사전에 설정된 보호자 또는 기관에 자동으로 전화를 거는 모니터링 및 알림 기능을 수행한다.

전체 프로세스는 크게 상태 데이터 수신, 위험 감지 로직, 자동 전화 발신, 그리고 웹 대시보드 업데이트의 네 단계로 구성된다.

- 상태 데이터 수신

딥러닝/머신러닝 프로세스의 추론 결과인 사용자 상태(Empty, Moving, Standing, Lying)를 UDP 소켓을 통해 수신한다. 딥러닝/머신러닝 프로세스는 추론 결과가 이전과 다른 경우에만 송신한다. 또한 sounddevice 라이브러리를 사용하여 오디오 마이크를 통해 주변 소리 데이터를 수집한다. 낙상이 발생할때 큰 소리를 임계값으로 정해두고, 해당 임계값을 초과하는 큰 소리가 발생한 시점을 지속적으로 기록한다.

- 위험 감지

단순히 사용자가 누워있는 상태만을 낙상으로 간주하지 않고, 큰 소리가 발생한 시점과의 시간 차이를 비교하여 복합적으로 판단한다. 큰 소리가 감지된 후 15초 이내에 사용자의 상태가 Lying로 변경될 경우, 시스템은 이를 일반적인 누움이 아닌 충격을 동반한 낙상 감지 상황으로 판별한다. 이는 추론 모델의 윈도우 사이즈 크기로 인한 딜레이를 고려하여 설정하였다.

- 자동 전화 발신

낙상 상황으로 판별되면, 시스템은 큐를 통해 백그라운드 스레드에 전화 발신을 요청한다. Twilio API를 연동하여 환경 변수에 사전 등록된 발신 번호(TWILIO_FROM_NUMBER)에서 보호자의 연락처(ALERT_PHONE_NUMBER)로 즉시 음성 통화를 시도하며, 지정된 템플릿에 따라 텍스트를 음성으로 변환하여 안내한다.




그림 20. Twilio API를 이용한 음성 통화 화면

- 웹 대시보드 업데이트

Flask 기반의 웹 서버를 통해 관리자와 보호자가 접근할 수 있는 대시보드를 제공하며, 화면 새로고침 없이 서버에서 데이터를 불러와 최신 상태를 유지한다.




그림 21. 웹 대시보드 화면

3.9. 전체 시스템 구성도




그림 22. 전체 시스템 구성도

시스템 구조는 크게 데이터 수집 및 전처리, 인공지능 기반 상태 추론, 낙상 9 판단 및 실시간 모니터링의 세 단계로 구성된다.

먼저 데이터 수집 및 전처리 단계에서는 ESP32 수신기를 활용한다. 실내 공간에 송출된 Wi-Fi 신호는 사람의 움직임에 의해 반사 및 회절을 겪으며 다중 경로 환경의 변화를 유발한다. 수신기는 재실자에 의해 왜곡된 신호를 수신하여 OFDM 통신 방식의 각 서브캐리어별 채널 주파수 응답을 나타내는 CSI 데이터를 실시간으로 추출하고, 이를 인공지능 추론 프로세스로 전달한다.

인공지능 기반 상태 추론 단계에서는 메인 프로세스가 수신기로부터 전달받은 CSI 시계열 데이터를 전처리한 후, 1D CNN 모델을 1차적으로 적용하여 재실자의 상태(Empty, Occupied)를 추론한다. 이후 1D CNN의 추론 결과를 기반으로 XGBoost 모델을 2차적으로 적용하여 최종적으로 세부 상태를 판별한다. 최종 추론 결과는 UDP 소켓 통신을 통해 낙상 판단 및 모니터링을 담당하는 별도의 프로세스로 전달된다.

마지막으로 낙상 판단 및 실시간 모니터링 단계에서는 해당 프로세스가 실내에서 발생하는 큰 소리를 감지하고, 인공지능 모델로부터 전달받은 상태 추론 결과를 수신하여 낙상 여부를 판단한다. 본 연구에서는 특정 기준 이상의 큰 소리가 발생한 이후 15초 이내에 인공지능 모델로부터 Lying 상태가 수신되는 경우를 낙상 상황으로 판단하도록 기준을 설정하였다.

낙상이 감지되면 해당 프로세스는 보호자에게 자동으로 전화를 걸어 상황을 알리며, 동시에 상태 및 낙상 감지 결과를 웹 기반 대시보드에 출력한다. 이를 통해 보호자는 원격에서도 대상자의 현재 상태와 낙상 발생 여부를 실시간으로 확인할 수 있다.

4. 연구 결과 분석 및 평가

4.1. 임계치 기반 재실 유무 탐지 결과




그림 23. 시간에 따른 진폭 분산 및 1~4Hz 주파수 에너지 변화 추이

측정 결과를 살펴보면 두 지표가 유사한 추세를 보이는 것을 알 수 있다. 공간 내에 사람의 움직임이 존재하는 구간(10~15초, 20~30초)에서는 두 수치가 높게 유지되지만, 사람이 퇴실하거나 완전한 정지 상태를 유지하는 구간(5~10초, 15~20초)에서는 수치가 급격히 하락함이 관측되었다.

실행 시간	진폭 분산	주파수 에너지	재실 유무 판별 결과
49.1	31.18797874	378.1084595	1
49.2	30.60311508	356.7941895	1
49.3	30.15510178	350.2645569	1
49.4	29.48429108	355.8590088	0
49.5	29.60929298	369.0174255	0
49.6	27.54317474	324.2199097	0
49.7	26.04083443	300.9173279	0

그림 24. 결과 CSV 파일 일부

위 그림의 CSV 데이터 로그는 추출된 두 가지 특성 값과 판별 결과가 타임스탬프에 맞춰 실시간으로 기록되었음을 보여준다. 또한 방을 나간 후 진폭 분산과 주파수 에너지가 떨어지는 것을 확인할 수 있다.

측정 시작후 방으로부터 나가기까지 결과는 무시하기 위해 측정 시작 5초 후부터 수집된 데이터를 CSV 파일로 저장했다. 5~10초 및 15~20초 구간은 방에 사람이 없는 상태로, 10~15초 및 20~30초 구간은 방에서 사람이 움직이는 상태로 설정해 측정하였다. 이 실제 상황과 임계치 기반 모델의 예측값을 csv파일에 저장된 값과 비교 분석한 결과 약 45.4%의 정확도를 확인했다.

실험 결과로 실시간 재실 탐지가 가능함을 확인하였으나, 현재 적용된 고정 임계치 방식은 환경이 변할 때마다 수동으로 임계치를 재설정해야하고, 설정한 임계치에 따라 정확도에 크게 달라지는 한계가 있다. 따라서 임계치 기반 탐지 로직은 향후 도입될 ML/DL 모델의 정상 동작 여부 및 성능 향상 폭을 객관적으로 비교 평가하기 위한 기초 기준으로 활용된다.

4.2. 딥러닝 모델(1D CNN)을 이용한 재실 유무 탐지 결과

아래 두 그림은 1D CNN 모델의 테스트 결과이다.

★ Final Test Results (Robust Normalization)				
	precision	recall	f1-score	support
empty	0.57	0.55	0.56	270
standing	0.62	0.58	0.60	270
moving	0.87	0.95	0.91	270
accuracy			0.70	810
macro avg	0.69	0.70	0.69	810
weighted avg	0.69	0.70	0.69	810

그림 25. 1D CNN 테스트 결과




그림 26. 1D CNN 테스트 결과 혼동 행렬

moving 레이블은 F1-score 0.91, 재현율(Recall) 0.95라는 높은 성능을 기록하였다. 혼동 행렬을 보면 실제 걷고 있는 상태를 빈 방(Empty)으로 완전히 잘못 인식한 경우는 0건이다. 이는 움직임이 만들어내는 CSI 신호의 큰 변동성은 1D CNN이 시간적 특징을 잡아내기에 매우 이상적이었음을 의미한다. 하지만 시간적 변동성이 작은 empty, standing의 경우에는 이를 구분할만한 패턴을 감지하지 못하는 모델의 한계를 보여준다.

4.3. 머신러닝 모델(XGBoost)을 이용한 재실 유무 탐지 결과

— Test 최종 성능 —

	precision	recall	f1-score	support
empty	0.50	0.19	0.27	280
standing	0.51	0.74	0.60	277
moving	0.78	0.94	0.85	278
accuracy			0.62	835
macro avg	0.60	0.62	0.58	835
weighted avg	0.60	0.62	0.58	835

그림 27. XGBoost 테스트 결과





그림 28. 테스트 데이터셋에 대한 혼동 행렬

도출된 혼동 행렬을 분석한 결과, Moving 레이블은 총 278개의 샘플 중 261개를 정확히 분류하여 93.9%의 높은 정확도를 기록하였다. 반면, Empty 상태의 테스트 데이터 280개 중 181개를 Standing으로 오분류하는 편향이 발생하였다.



특징 중요도 분석 결과, 평균(Mean)이나 표준편차(Std)보다 왜도(Skewness), 첨도(Kurtosis), 최댓값과 같은 분포 기반 통계량의 기여도가 높게 나타났으며, 52개 서브캐리어 중에서도 특정 서브캐리어(sc20, sc60, sc44)에 중요도가 집중되는 경향을 보였다.

그림 30. 실시간 추론 모니터링 터미널

Moving 의 경우 높은 신뢰도로 정확하게 탐지해 내는 우수한 성능을 보인 반면, Empty

와 Standing 구간에서는 두 상태를 빈번하게 오분류하는 한계점이 실시간 추론 환경에서도 확인되었다.

4.4. 데이터셋 구성 확장 결과

4.4.1. 2인 데이터셋 추가 결과

아래 표는 XGBoost 모델의 학습 과정에서 전처리 조건을 A와 B 두 가지 경우로 구분하고, 각 조건에서 (윈도우 사이즈 / 슬라이딩 사이즈)를 변화시켰을 때의 Test Accuracy를 비교한 결과이다. A 조건은 FFT Shift를 적용하고 정규화 및 서브캐리어 필터링을 적용하지 않은 경우이며, B 조건은 FFT Shift를 적용한 후 Z-score 정규화와 서브캐리어 필터링을 적용한 경우이다.

	(100 / 10)	(100 / 20)	(100 / 30)	(100 / 40)	(200 / 10)	(200 / 20)	(200 / 30)	(200 / 40)
A	0.8426	0.8467	0.8455	0.8456	메모리 초과	0.8614	0.8527	0.8540
B	0.8429	0.8445	0.8445	0.7937	메모리 초과	0.8137	0.8527	0.8226

표 6. 조건별 Test Accuracy

A와 B 조건에 따른 Test Accuracy의 차이는 크지 않은 것으로 확인되었다. 이에 따라 전처리 조건에 따른 성능 차이보다는 실시간 상태 추론에 적합한 윈도우 크기와 슬라이딩 크기를 고려하여 파라미터를 선정하였다. 윈도우 크기는 충분한 시계열 정보를 포함할 수 있도록 200으로 설정하였으며, 슬라이딩 크기는 추론 결과를 빠르게 갱신할 수 있도록 40으로 설정하였다. 따라서 최종적으로 윈도우 크기 200, 슬라이딩 크기 40을 적용하였다. 아래 그림은 해당 결과이다.

Test Accuracy: 0.8540

	precision	recall	f1-score	support
empty	0.83	0.95	0.89	504
p1_moving	0.88	0.98	0.93	502
p1_standing	0.82	0.70	0.76	502
p2_mixed	0.91	0.69	0.79	500
p2_moving	0.82	0.95	0.88	503
p2_standing	0.88	0.84	0.86	503
accuracy			0.85	3014
macro avg	0.86	0.85	0.85	3014
weighted avg	0.86	0.85	0.85	3014

그림 31. XGBoost 테스트 결과




그림 32. 테스트 데이터셋에 대한 혼동 행렬

혼동행렬을 통해 확인한 결과, 테스트 데이터에서는 전체적으로 양호한 분류 성능을 보

였으며 Test Accuracy는 85.40%로 나타났다. 그러나 실제 실시간 추론 프로세스에서는 오프라인 테스트 결과와 차이가 나타났으며, Empty와 p1_moving 상태의 추론은 90% 이상의 높은 정확도를 보인 반면, p1_standing, p2_mixed, p2_moving, p2_standing 상태는 정확도가 50% 미만으로 매우 낮은 분류 성능을 보였다. 따라서 이후 학습에서 2인 데이터셋은 제거하였다.

4.4.2. 낙상 데이터셋 추가 결과

윈도우 사이즈, 슬라이딩 사이즈는 이전과 같이 200, 40패킷으로 설정하였다.

Test Accuracy: 0.9063				
	precision	recall	f1-score	support
empty	0.82	0.96	0.88	679
fall	0.83	0.88	0.86	17
moving	0.98	0.98	0.98	676
standing	0.94	0.78	0.86	678
accuracy			0.91	2050
macro avg	0.89	0.90	0.89	2050
weighted avg	0.91	0.91	0.91	2050

그림 33. XGBoost 테스트 결과




그림 34. 테스트 데이터셋에 대한 혼동 행렬

낙상 데이터를 추가한 후 2인 데이터를 제외한 데이터셋을 대상으로 평가한 결과, Test Accuracy는 0.9063으로 높은 분류 성능을 보였다. 그러나 실제 실시간 추론 환경에서는 성능이 낮게 나타나는 것을 확인하였다. 실시간 추론에서는 Empty와 Moving 상태는 비교적 안정적으로 검출되었으나, 낙상 상태의 경우 실시간 프로세스를 실행하는 시간대 및 환경에 따라 검출 결과의 편차가 크게 나타났다. 일부 경우에는 낙상이 한 번도 검출되지 않았으며, 검출되는 경우에도 50% 미만의 낮은 성능을 보여 실제 환경에서 낙상을 안정적으로 판별하기에는 한계가 있음을 확인하였다.

따라서 이후 실험에서는 낙상 레이블을 데이터셋에서 제외하고, 낙상 이후의 상태를 나타내는 Lying 레이블을 추가하였다. 또한 CSI 데이터만을 이용한 상태 판별의 한계를 보완하기 위해 RSSI를 추가적인 지표로 활용하였으며, 마이크를 통해 측정된 소리의 크기 (dB)를 함께 사용하여 낙상 상황을 판별하도록 시스템을 구성하였다.

4.5. 계층적 상태 정보 추론 모델 결과




그림 35. 재실 유무 판별 모델 학습 곡선




그림 36. 재실 유무 판별 모델 혼동 행렬

먼저 재실 유무 판별 모델 결과이다.

학습 곡선에서 확인할 수 있듯이, 학습 데이터에 대한 정확도는 지속적으로 상승하여 최종적으로 98% 이상에 도달했다. 검증 데이터의 정확도 역시 에포크 2에서 일시적으로

하락했으나, 이후 반등하여 최종적으로 약 90% 수준까지 점진적으로 상승하는 이상향 추세를 보였다. 검증 손실은 에포크 1 이후부터 감소하지 않고 오히려 상승하거나 변동하는 형태를 보이고 있다. 이는 과적합의 징후로 볼 수 있다.

혼동 행렬을 살펴보면, 실제 사람이 있는 경우(640건) 중 605건을 정확히 예측하여 약 94.5%의 높은 재현율을 기록했다. 또한 실제 빈 공간인 경우(240건) 중 207건을 정확히 예측하여 약 86.2%의 재현율을 보였다. 빈 공간을 재실로 잘못 판단한 경우가 33건, 재실을 빈 공간으로 잘못 판단한 경우가 35건으로 두 오류가 비슷한 수준으로 발생했다. 전체 880건의 검증 데이터 중 812건을 정확히 분류하여 전체 정확도는 약 92.2% 수준이다.

다음으로 사용자 동작 분류 모델의 결과이다.




그림 37. 사용자 동작 분류 모델 혼동 행렬

혼동 행렬을 분석한 결과, 검증 데이터에 대해 약 88.7%의 전반적인 분류 정확도를 기록하며 양호한 성능을 보여주었다.

세부 동작별로 살펴보면 Moving 클래스에서 가장 우수한 결과가 나타났다. 움직이기 상

태는 실제 240건 중 234건을 정확히 예측하여 97.5%라는 높은 재현율을 달성하여 모델이 움직임이 있는 상태를 매우 뚜렷하게 감지해 내고 있음을 알 수 있다.

반면 상대적으로 정적인 상태인 서 있기과 눕기 클래스 사이에서는 오분류 현상이 관찰되었다. 서 있기 상태는 전체 240건 중 198건을 정확히 분류하여 82.5%의 재현율을 보였으며, 37건을 눕기로 잘못 예측했다. 눕기 상태의 경우 전체 120건 중 100건을 맞추어 83.3%의 재현율을 기록했고, 20건을 서 있기로 잘못 판단했다. 눕기와 움직이기 사이의 오분류는 양방향 모두 0건으로 두 상태는 완벽하게 구별되고 있으나, 서 있기과 눕기라는 두 정적 상태 간의 특징적 유사성으로 인해 혼동이 발생하는 것으로 분석된다.

추가적으로 실제 환경에서 실시간 추론 테스트를 진행한 결과, 데이터를 수집한 당일에 모델을 학습시키고 추론을 수행했을 때는 약 90% 이상의 수준의 우수한 성능을 보였다. 하지만 데이터 수집일과 다른 날에 실시간 추론을 진행해 본 결과, 설치된 ESP32 기기의 미세한 위치나 각도 틀어짐 같은 물리적 환경의 변화로 인해 추론 성능이 다소 낮아지는 현상이 관찰되었다.

4.6. 윈도우 및 슬라이딩 사이즈에 따른 성능 평가

모델의 분류 성능과 실시간 처리 효율성을 높이기 위해, 재실 판별 모델(1D CNN)과 동작 분류 모델(XGBoost)에 적용할 입력 데이터의 윈도우 사이즈 및 슬라이딩 사이즈에 따른 성능 비교를 하였다. 각 조건에서 도출된 평균 균형 정확도(BAcc)를 비교하여 최적의 크기를 선정하였다.

아래 표는 각 파라미터 조합에 따른 성능 평가 결과를 나타낸다. 표 안의 수치는 재실 판별 모델 BAcc / 동작 분류 모델 BAcc 형태로 기재되었다. 표의 가로축(열)은 (1D CNN 윈도우 사이즈, XGBoost의 윈도우 사이즈) 조합을 나타내며, 세로축(행)은 슬라이딩 사이즈를 의미한다.

	(200, 80)	(200, 120)	(400, 80)	(400, 120)
20	88.90 / 95.72	88.90 / 94.50	88.09 / 95.72	88.09 / 96.94
40	88.25 / 95.73	88.25 / 94.58	85.61 / 95.73	85.61 / 94.58
60	90.11 / 95.52	90.11 / 94.34	84.84 / 95.52	84.84 / 94.34

표 7. 윈도우 사이즈 및 슬라이딩 사이즈별 BAcc

단순히 가장 높은 분류 확률을 기록한 설정을 선택하기보다는 윈도우 사이즈에 따른 안정성과 슬라이딩 사이즈에 따른 실시간성을 고려하였다. 이에 따라 두 계층 모델 모두에서 한쪽으로 치우치지 않고 안정적인 판단력을 유지하면서도 연산 효율성을 확보할 수 있는 지점인 슬라이딩 사이즈 40패킷, 윈도우 사이즈 (400, 120) 조합이 가장 적합하다고 판단하여 최종 파라미터로 적용하였다.

4.7. 재실 판별 모델 종료 조건 평가

초기 실험(patience=5) 모델의 학습 곡선을 분석한 결과 과적합 징후가 관찰되었다. 검증 손실이 에포크 1 이후 지속적으로 상승하는 현상을 확인하여, 학습 과정을 더 지켜보기 위해 조기 종료 조건인 patience를 10과 15로 연장하였다.




그림 38. Patience = 10 일 때의 학습 곡선




그림 39. Patience = 15 일 때의 학습 곡선

에포크가 10과 15까지 진행됨에 따라 두 가지 상반된 양상이 뚜렷하게 나타났다.

먼저, 손실 측면에서의 과적합 심화이다. 학습 손실은 에포크가 진행될수록 0 에 가깝게 수렴하며 모델이 주어진 학습 데이터를 학습하고 있음을 보여준다. 반면, 검증 손실은 에포크 1 부근에서 최저점을 기록한 이후 급격히 상승하여 0.35~0.40 구간에서 불안정하게 요동치는 현상을 보였다.

다음으로, 정확도 측면에서의 상승이다. 검증 손실이 지속적으로 악화됨에도 불구하고 검증 정확도는 점진적으로 우상향하여 에포크 10 에서는 약 91%, 에포크 15 부근에서는 약 92~93% 수준까지 도달했다. 이는 모델이 틀린 문제에 대해서는 잘못된 확신을 가져 페널티를 크게 받지만, 전체적인 정답의 개수 자체는 학습을 진행할수록 미세하게 늘어나고 있음을 의미한다.

결과적으로 patience 값을 늘려 학습을 오래 유지하면 정확도는 일부 상승하지만, 과적합을 동반하므로 실제 환경에 투입했을 때의 일반화 성능을 보장하기 어려움을 알 수 있다.

5. 결론 및 향후 연구 방향

본 연구에서는 WiFi CSI 데이터와 소리 데이터를 활용하여 실시간 재실 판별 및 사용자 동작 분류, 그리고 낙상 감지와 연동된 자동 긴급通報 시스템을 구현하고 그 성능을 평가하였다. 1D CNN과 XGBoost를 결합한 계층적 모델은 통제된 수집 환경에서는 우수한 성능을 보여주었으나, 다른 환경에서는 한계점을 보였다.

가장 주요한 한계점은 현재 시스템이 주변 환경 변화에 매우 민감하게 반응한다는 것이다. 데이터를 수집한 당일에는 높은 정확도를 보였으나 다른 날짜에 테스트를 진행하거나 ESP32의 미세한 위치 및 각도 틀어짐이 발생했을 때 추론 성능이 다소 저하되는 현상이 확인되었다. 이를 통해 현재 학습된 모델이 특정 환경과 초기 설치 조건에 강하게 종속되어 있음을 알 수 있다.

이러한 환경적 제약을 극복하고 시스템의 상용화 수준을 높이기 위해서는 장기간에 걸친 광범위한 데이터 수집이 필수적이라고 생각한다. 향후 연구에서는 다양한 구조의 실내 공간, 다양한 체형 및 행동 패턴을 가진 사용자, 그리고 여러 계절과 시간대에 걸친 양질의 데이터를 지속적으로 확보해야 한다. 이러한 장기 데이터를 바탕으로 모델을 고도화한다면, 기기의 물리적 틀어짐이나 일상적인 환경 노이즈 변화에 대한 모델의 강건성과 일반화 성능을 크게 향상시킬 수 있을 것이다.

또한, 수집되는 데이터의 규모와 품질이 개선된다면 현재의 낙상 탐지 알고리즘 구조를 개선할 수 있다고 생각한다. 현재 시스템은 모델이 예측한 눕기 상태와 임계치 이상의 큰 소리 감지라는 두 가지 개별 지표를 통해 낙상을 판단하는 방식을 취하고 있다. 향후 실제 낙상 상황에 대한 양질의 시계열 데이터를 충분히 확보한다면, 소리 데이터에 대한 의존도를 낮추고 와이파이 신호의 미세한 주파수 변화 패턴만으로 비정상적인 추락을 직접 찾아내거나, 딥러닝 모델 내에서 낙상을 하나의 독립적인 동작 클래스로 완벽하게 분류해 내는 등 더욱 발전된 형태의 탐지 기법을 적용할 수 있을 것으로 기대된다.

6. 구성원별 역할 및 개발 일정

6.1. 구성원별 역할

학번	성명	구성원별 역할
202255660	박진석	- ESP32 기반 CSI 데이터 송수신 시스템의 펌웨어 개발 - 실내 다중경로 및 LoS 환경에서 CSI 데이터 수집 후 시각화 및 분석을 통한 송수신기 최적 배치 실험 수행 - 1D CNN 기반 재실 판별 모델과 XGBoost 기반 사용자 동작 분류 모델을 결합한 2단계 계층적 추론 모델 개발 및 실시간 추론 시스템 개발
202155527	김민준	- CSI 데이터의 특징 분석 및 환경 잡음 제거를 위한 신호 처리 - CSI 데이터의 진폭 및 PSD 실시간 시각화 프로세스 및 임계치 기반 재실 탐지 모델 개발 - 계층적 추론 모델의 조건별 성능 비교 시스템 구축 - 추론 결과 기반 실시간 상태 모니터링 대시보드 및 긴급 전화 시스템 개발
202055624	홍정기	- ESP32 기반 CSI 송수신 시스템의 펌웨어 최적화 및 모듈화 - 실험 데이터셋 수집 시나리오 설계 및 데이터 수집 자동화 파이프라인 구축 - CSI 시계열 데이터를 활용한 1D CNN 기반의 실시간 재실 판별 모델 및 XGBoost 기반 CSI 데이터 분류 모델 구축 및 파라미터 튜닝을 통한 성능 개선 - Colab 환경을 활용한 모델별 학습 성능 비교 시스템 구축

표 8. 구성원별 역할

6.2. 개발 일정



그림 40. 개발 일정 간트 차트

7. 참고 문헌

- [1] 모형근, 김승구, "WiFi CSI를 활용한 머신러닝 기반 신원 확인 시스템," 『2020년도 한국통신학회 하계종합학술발표회 논문집』, 2020, pp. 133–134.
- [2] H. Lee, C. R. Ahn, and N. Choi, "Exploiting Multiple Receivers for CSI-Based Activity Classification Using a Hybrid CNN-LSTM Model," in Proceedings of the 1st ACM International Workshop on Device-Free Human Sensing (DFHS '19), New York, NY, USA, Nov. 2019, pp. 18–21, doi: 10.1145/3360773.3360878.
- [3] A. Dempster, D. F. Schmidt, and G. I. Webb, "MiniRocket: A Very Fast (Almost) Deterministic Transform for Time Series Classification," in Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining (KDD '21), Aug. 2021, pp. 248–257, doi: 10.1145/3447548.3467231.
- [4] F. Deng, E. Jovanov, H. Song, W. Shi, Y. Zhang, and W. Xu, "WiLDAR: WiFi Signal-Based Lightweight Deep Learning Model for Human Activity Recognition," IEEE Internet of Things Journal, vol. 11, no. 2, pp. 2899–2908, Jan. 2024, doi: 10.1109/JIOT.2023.3294004.
- [5] H. Salehinejad and S. Valaee, "LiteHAR: Lightweight Human Activity Recognition from WiFi Signals with Random Convolution Kernels," in Proceedings of the 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Singapore, May 2022, pp. 4068–4072, doi: 10.1109/ICASSP43922.2022.9746803.
- [6] P. Sruthi and S. K. Udgata, "Wi-Fi Sensing Based Person Identification and Activity Recognition Using Two-Phase Deep Learning Model," Engineering Applications of Artificial Intelligence, vol. 132, Art. no. 107904, Jun. 2024, doi: 10.1016/j.engappai.2024.107904.
- [7] M. Matey-Sanz, J. Torres-Sospedra, and A. Moreira, "Temporal Stability on Human Activity Recognition Based on Wi-Fi CSI," in Proceedings of the 2023 International Conference on Indoor Positioning and Indoor Navigation (IPIN), Nuremberg, Germany, Sep. 2023, pp. 1–6, doi: 10.1109/IPIN57070.2023.10332214.
- [8] J. Guo, W. Zhuang, Y. Mao, and I. W.-H. Ho, "RSSI-Assisted CSI-Based Passenger Counting with Multiple Wi-Fi Receivers," in Proceedings of the 2025 IEEE Wireless Communications and Networking Conference (WCNC), Milan, Italy, Mar. 2025, pp. 1–6, doi: 10.1109/WCNC61545.2025.10978465.
- [9] A. Dempster, F. Petitjean, and G. I. Webb, "ROCKET: Exceptionally Fast and Accurate Time Series

Classification Using Random Convolutional Kernels," *Data Mining and Knowledge Discovery*, vol. 34, no. 5, pp. 1454–1495, Sep. 2020, doi: 10.1007/s10618-020-00701-z.

[10] A. Y. Radwan, M. Yildirim, N. Hasanzadeh, H. Tabassum, and S. Valaee, "A Tutorial-cum-Survey on Self-Supervised Learning for Wi-Fi Sensing: Trends, Challenges, and Outlook," *arXiv preprint arXiv:2506.12052*, May 2025, doi: 10.48550/arXiv.2506.12052.

[11] D. Halperin, W. Hu, A. Sheth, and D. Wetherall, "Tool Release: Gathering 802.11n Traces with Channel State Information," *ACM SIGCOMM Computer Communication Review*, vol. 41, no. 1, p. 53, Jan. 2011, doi: 10.1145/1925861.1925870.

[12] C. Han, K. Wu, Y. Wang, and L. M. Ni, "WiFall: Device-Free Fall Detection by Wireless Networks," in *Proceedings of IEEE INFOCOM 2014 - IEEE Conference on Computer Communications*, Toronto, ON, Canada, Apr./May 2014, pp. 271–279, doi: 10.1109/INFOCOM.2014.6847948.

[13] H. Wang, D. Zhang, Y. Wang, J. Ma, Y. Wang, and S. Li, "RT-Fall: A Real-Time and Contactless Fall Detection System with Commodity WiFi Devices," *IEEE Transactions on Mobile Computing*, vol. 16, no. 2, pp. 511–526, Feb. 2017, doi: 10.1109/TMC.2016.2557795.

[14] J. Kim, K. Min, M. Jung, and S. Chi, "Occupant Behavior Monitoring and Emergency Event Detection in Single-Person Households Using Deep Learning-Based Sound Recognition," *Building and Environment*, vol. 181, Art. no. 107092, Aug. 2020, doi: 10.1016/j.buildenv.2020.107092.